BỘ KHOA HỌC VÀ CÔNG NGHỆ

**HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG**

**CƠ SỞ TẠI TP. HỒ CHÍ MINH**

Khoa/đơn vị: **Khoa Công nghệ Thông tin 2**

**ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN**

Mã số đề tài: **09-SV-2026-CNTT2**

# NGHIÊN CỨU ENSEMBLE LEARNING CHO BÀI TOÁN PHÁT HIỆN XÂM NHẬP MẠNG

Thực nghiệm phân loại nhị phân trên UNSW-NB15

| | | |
|---|---|---|
| **Sinh viên thực hiện:** | Dương Ngọc Phú | N23DCDK055 |
| | Phạm Thế Vỹ | N23DCCN205 |
| | Vũ Văn Kiên | N23DCDT029 |
| | Lê Hoàng Nguyên Quân | N23DCDT042 |
| **Lớp:** | E23CQCE01-N | |
| **Giảng viên hướng dẫn:** | Lê Ngọc Hiếu | |

**TP. Hồ Chí Minh – 10/10/2026**

# LỜI CAM ĐOAN

Nhóm sinh viên thực hiện đề tài gồm Dương Ngọc Phú (N23DCDK055), Phạm Thế Vỹ (N23DCCN205), Vũ Văn Kiên (N23DCDT029) và Lê Hoàng Nguyên Quân (N23DCDT042), thuộc lớp E23CQCE01-N, dưới sự hướng dẫn của giảng viên Lê Ngọc Hiếu.

Chúng em xác nhận rằng các nội dung mô tả quy trình, dữ liệu và kết quả thực nghiệm trong báo cáo được trình bày nhất quán với dữ liệu, chương trình thực nghiệm và bảng kết quả. Các công trình tham khảo được trích dẫn; các giới hạn về mẫu, thiết kế kiểm định và khả năng tái lập được công khai để người đọc có thể đánh giá phạm vi kết luận.

Nhóm sinh viên chịu trách nhiệm tự kiểm tra tính chính xác và tính nguyên gốc của bản báo cáo trước khi nộp theo quy định của Học viện. Việc ký tên xác nhận do chính các thành viên thực hiện khi hoàn thiện hồ sơ nộp.

TP. Hồ Chí Minh, ngày 10 tháng 10 năm 2026

Nhóm sinh viên thực hiện

# LỜI CẢM ƠN

Nhóm sinh viên trân trọng cảm ơn giảng viên hướng dẫn Lê Ngọc Hiếu đã đồng hành trong quá trình thực hiện đề tài nghiên cứu khoa học về Ensemble Learning cho phát hiện xâm nhập mạng.

Chúng em cảm ơn các thầy cô của Khoa Công nghệ Thông tin 2, Học viện Công nghệ Bưu chính Viễn thông, vì nền tảng kiến thức và môi trường học thuật hỗ trợ quá trình học tập, nghiên cứu. Báo cáo được thực hiện dựa trên những dữ liệu và nguồn tham khảo có ghi nhận, với mong muốn làm rõ chất lượng thực nghiệm cũng như những hạn chế khi ứng dụng các mô hình học máy cho NIDS.

Nhóm mong nhận được những ý kiến nhận xét và phản biện để tiếp tục hoàn thiện nghiên cứu.

TP. Hồ Chí Minh, ngày 10 tháng 10 năm 2026

Nhóm sinh viên thực hiện

# MỤC LỤC

**Lời cam đoan** i

**Lời cảm ơn** ii

**Danh mục từ viết tắt** v

**Chương 1 CƠ SỞ LÝ THUYẾT** 1

1.1 Bối cảnh và mục tiêu nghiên cứu . . . . . 1
1.1.1 Bối cảnh và động cơ . . . . . 1
1.1.2 Vấn đề nghiên cứu . . . . . 1
1.1.3 Các vấn đề nghiên cứu . . . . . 2
1.1.4 Mục tiêu và đóng góp nghiên cứu . . . . . 2
1.1.5 Bố cục báo cáo . . . . . 3
1.2 Các thuật toán học máy và phương pháp kết hợp . . . . . 3
1.2.1 Phát hiện xâm nhập dựa trên đặc trưng luồng mạng . . 3
1.2.2 Mô hình Logistic Regression . . . . . 4
1.2.3 Decision Tree và Random Forest . . . . . 5
1.2.4 Voting, Stacking và sai số bổ sung . . . . . 6
1.2.5 Các chiến lược Feature Selection . . . . . 7
1.2.6 Các chỉ số đánh giá và diễn giải thống kê . . . . . 8
1.3 Các công trình nghiên cứu liên quan . . . . . 9
1.3.1 Ensemble Learning trong NIDS . . . . . 9
1.3.2 Feature Selection, chuẩn hóa và mất cân bằng . . . . . 9
1.3.3 Chất lượng dữ liệu và khả năng khái quát . . . . . 9
1.3.4 Khoảng trống bằng chứng và giới hạn tổng quan . . . . 10
1.3.5 Đối chiếu trực tiếp với các nghiên cứu gần phương pháp 10

**Chương 2 DỮ LIỆU VÀ QUY TRÌNH TIỀN XỬ LÝ** 12

2.1 Nguồn dữ liệu và quy mô bản ghi . . . . . 12
2.2 Các nhóm tấn công và mức độ chênh lệch . . . . . 12
2.3 Khảo sát thống kê các đặc trưng . . . . . 14
2.4 Tương quan giữa các đặc trưng . . . . . 15
2.5 Kiểm toán overlap và các view đánh giá . . . . . 16
2.6 Kết luận về đặc trưng của benchmark . . . . . 16

**Chương 3 XÂY DỰNG MÔ HÌNH VÀ THIẾT KẾ THỰC NGHIỆM 17**
3.1 Thiết kế và tập dữ liệu . . . 17
3.2 Feature selection và preprocessing . . . 17
3.3 Các pipeline được khóa trước final evaluation . . . 18
3.4 Các bước triển khai và huấn luyện . . . 19
3.5 Final evaluation, uncertainty và sai số . . . 19
3.6 Các giới hạn về tái lập và tính hợp lệ . . . 20

**Chương 4 KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ 21**
4.1 Phạm vi đánh giá và cách đọc các chỉ số . . . 21
4.2 Kết quả trên official holdout . . . 21
4.3 Khoảng tin cậy và kiểm định cặp . . . 22
4.4 Chi phí mô hình và số đặc trưng . . . 23
4.5 Phân tích lỗi theo họ tấn công . . . 24
4.6 Kiểm tra độ nhạy trên nhóm vector chưa trùng . . . 24
4.7 Bằng chứng development: Voting, OOF và diversity . . . 25
4.8 Trả lời cụ thể năm câu hỏi nghiên cứu . . . 25
4.8.1 RQ1: Ensemble có cải thiện ổn định so với mô hình đơn? 25
4.8.2 RQ2: Feature Selection thay đổi chất lượng và chi phí ra sao? . . . 26
4.8.3 RQ3: Sai số bổ sung có liên hệ với kết quả Ensemble? . 26
4.8.4 RQ4: Mô hình thay đổi khi loại vector TEST trùng TRAIN? 26
4.8.5 RQ5: Xử lý mất cân bằng ảnh hưởng lỗi như thế nào? . 27

**Chương 5 THẢO LUẬN VÀ HƯỚNG PHÁT TRIỂN 28**
5.1 Tại sao điểm số tổng thể chưa đủ . . . 28
5.2 Sai số theo nhóm tấn công . . . 29
5.3 Vai trò và giới hạn của Feature Selection . . . 29
5.4 Sự khác biệt giữa kiểm định, bootstrap và độ ổn định . . . 29
5.5 Giới hạn tái lập và kiểm tra artifact mới nhất . . . 30
5.6 Tính hợp lệ bên ngoài và định hướng nghiên cứu tiếp . . . 30
5.7 Tổng hợp kết luận theo câu hỏi nghiên cứu . . . 31
5.8 Kết luận và định hướng phát triển . . . 32
5.8.1 Tổng kết kết quả . . . 32
5.8.2 Giải đáp các câu hỏi nghiên cứu . . . 32
5.8.3 Đóng góp trong phạm vi đã chứng minh . . . 33
5.8.4 Công việc còn thiếu và hướng nghiên cứu . . . 33
5.8.5 Kết luận cuối . . . 34

**Tài liệu tham khảo 35**

# DANH MỤC TỪ VIẾT TẮT

| Ký hiệu | Thuật ngữ đầy đủ | Ý nghĩa trong nghiên cứu |
|---|---|---|
| IDS | Intrusion Detection System | Hệ thống giám sát và phát hiện hoạt động có dấu hiệu xâm nhập. |
| NIDS | Network Intrusion Detection System | Hệ thống IDS phân tích dữ liệu lưu lượng mạng để nhận biết hành vi tấn công. |
| ML | Machine Learning | Phương pháp học quy luật từ dữ liệu nhằm dự đoán nhãn của lưu lượng mới. |
| RF | Random Forest | Bộ phân loại kết hợp nhiều cây quyết định để dự đoán nhãn hoặc xác suất tấn công. |
| LR | Logistic Regression | Bộ phân loại ước lượng xác suất thuộc lớp Attack từ các đặc trưng đầu vào. |
| DT | Decision Tree | Mô hình phân loại dựa trên các nhánh điều kiện đối với giá trị đặc trưng. |
| OOF | Out-of-Fold | Dự đoán trên phần dữ liệu không dùng để huấn luyện mô hình ở lượt chia fold tương ứng. |
| CV | Cross-Validation | Phương pháp chia tập huấn luyện thành nhiều phần để ước lượng chất lượng khi phát triển mô hình. |
| FS | Feature Selection | Quá trình chọn tập đặc trưng đầu vào nhằm cân bằng thông tin dự đoán và chi phí tính toán. |
| EDA | Exploratory Data Analysis | Khảo sát phân bố, chất lượng dữ liệu và quan hệ giữa các đặc trưng trước huấn luyện. |
| TP | True Positive | Số mẫu Attack được mô hình dự đoán đúng là Attack. |
| TN | True Negative | Số mẫu Normal được mô hình dự đoán đúng là Normal. |

| Ký hiệu | Thuật ngữ đầy đủ | Ý nghĩa trong nghiên cứu |
|---|---|---|
| FP | False Positive | Số mẫu Normal bị nhận nhầm là Attack (cảnh báo giả). |
| FN | False Negative | Số mẫu Attack bị nhận nhầm là Normal (tấn công bị bỏ sót). |
| FPR | False Positive Rate | Tỷ lệ Normal bị cảnh báo nhầm, tính bằng FP/(FP+TN). |
| FNR | False Negative Rate | Tỷ lệ Attack bị bỏ sót, tính bằng FN/(FN+TP). |
| F1 | F1-score | Trung bình điều hòa của Precision và Recall; phản ánh chất lượng cân bằng giữa hai đại lượng. |
| MCC | Matthews Correlation Coefficient | Chỉ số tương quan giữa nhãn thật và dự đoán, sử dụng đủ bốn ô ma trận nhầm lẫn. |
| CI | Confidence Interval | Khoảng giá trị ước lượng thể hiện bất định của một đại lượng thống kê theo quy trình đã chọn. |
| AP | Average Precision | Chỉ số tóm tắt quan hệ Precision–Recall theo các ngưỡng dự đoán. |
| SMD | Standardized Mean Difference | Mức chênh lệch trung bình giữa hai nhóm, quy đổi theo độ phân tán của đặc trưng. |

# DANH SÁCH HÌNH VẼ

Hình 1.1 Sơ đồ nguyên lý Stacking/OOF và ranh giới official TEST. Hình chỉ minh họa giao thức, không chứng minh nested validation đầy đủ. . . . . 7

Hình 2.1 Phân bố nhãn Normal/Attack trong official TRAIN và TEST, biểu đồ phân bố lớp từ kết quả khảo sát dữ liệu. . . . . 13

Hình 2.2 Số lượng bản ghi theo `attack_cat` của hai tập. Trong nghiên cứu hiện tại, đây là phân tích nhãn thật chứ không phải kết quả một mô hình multiclass. . . . . 13

Hình 2.3 Khảo sát mức tách biệt Normal/Attack ở một số feature số trên tập huấn luyện. Không dùng biểu đồ này để suy ra quan hệ nhân quả. . . . . 14

Hình 2.4 Ma trận tương quan các feature số trên tập huấn luyện. Mối tương quan mạnh không tự chứng minh hai biến là tương đương về cơ chế hay có thể loại bỏ không làm mất thông tin. . . . . 15

Hình 4.1 Chênh lệch số lượng lỗi Stacking-42 trừ RF-42 trên cùng official TEST: FP giảm 142 mẫu và FN tăng 118 mẫu. Số lượng quan sát trên benchmark cố định, không phải sai khác trung bình qua nhiều lần huấn luyện. . . . . 22

Hình 4.2 Bốn hiệu số Stacking-42 trừ RF-42 và CI 95% paired bootstrap đã lưu. Giá trị trục ngang là hiệu số nhân 100 (không phải phần trăm thay đổi tương đối). CI của Macro-F1 và MCC chứa 0; FPR giảm, FNR tăng. . . . . 23

# DANH SÁCH BẢNG

Bảng 1.1 Đối chiếu phạm vi phương pháp với công trình liên quan; khác giao thức thì không xếp hạng trực tiếp điểm số. . . . 11

Bảng 2.1 Phân bố hai lớp của các tập UNSW-NB15 chính thức. . . . 12
Bảng 2.2 Hai góc nhìn đánh giá cùng thuộc official TEST đã lưu. . . 16

Bảng 3.1 Cấu hình pipeline cuối theo frozen manifest. . . . . 18

Bảng 4.1 Hiệu năng nhị phân của ba pipeline trên official TEST (82 332 mẫu; threshold 0,5). FPR và FNR tính theo phần trăm. . . . . 21
Bảng 4.2 Chênh lệch Stacking-42 trừ RF-42 và CI 95% paired bootstrap đã lưu; 10 000 lần lấy mẫu bootstrap từ các dòng benchmark. Đơn vị là độ chênh tuyệt đối trên thang 0–1. . . . . 22
Bảng 4.3 Chi phí được ghi nhận trong lần chạy lịch sử. Kích thước sử dụng đơn vị MiB (byte chia $1024^2$), không phải MB thập phân. . . . . 23
Bảng 4.4 Số mẫu Attack thực bị dự đoán là Normal, phân nhóm theo `attack_cat`; đây không phải đánh giá multiclass. . . . . 24
Bảng 4.5 Macro-F1 trên official TEST và phần novel-vector của cùng official TEST. Novel-vector *không* phải bộ dữ liệu kiểm thử độc lập. . . . . 24
Bảng 4.6 Development pooled OOF trên track 42 biến. FPR/FNR tính bằng %; giữ cả Voting bất lợi. . . . . 25
Bảng 4.7 RQ4: Macro-F1 trong cùng official TEST, không phải validation độc lập. . . . . 27

Bảng 5.1 Tính đúng/sai của RF-42 và Stacking-42 theo từng cặp dự đoán, official TEST. . . . . 28
Bảng 5.2 Câu trả lời theo phạm vi đã có bằng chứng, không phải kết luận giả định. . . . . 31

# Chương 1. CƠ SỞ LÝ THUYẾT

## 1.1 Bối cảnh và mục tiêu nghiên cứu

### 1.1.1 Bối cảnh và động cơ

Hệ thống phát hiện xâm nhập mạng (Network Intrusion Detection System, NIDS) nhằm nhận diện lưu lượng có dấu hiệu tấn công từ các quan sát mạng. Các bộ phân loại học máy có thể phát hiện những mẫu phức tạp trong dữ liệu flow, nhưng điểm số cao trên một benchmark không tự bảo đảm hiệu quả trong các bối cảnh triển khai khác nhau. Cách tạo và làm sạch dữ liệu, lựa chọn đặc trưng, chia tập và các loại sai số có thể ảnh hưởng đáng kể đến diễn giải thí nghiệm.

Ensemble Learning kết hợp dự đoán từ nhiều bộ phân loại. Tổng quan hệ thống của Tama và Lim nhấn mạnh hai khía cạnh thiết kế là lựa chọn mô hình thành viên và phương pháp kết hợp [10]. Những thành phần như Voting, Stacking hay Feature Selection đã xuất hiện trong công trình liên quan, vì vậy *chỉ áp dụng chúng không thể tự xem là một thuật toán mới* [3, 5, 11, 7]. Giá trị của so sánh cần đến từ protocol có truy vết, thước đo thể hiện đúng loại lỗi, đối chiếu chi phí và cách diễn giải độ bất định.

### 1.1.2 Vấn đề nghiên cứu

Nghiên cứu tập trung vào bài toán nhị phân **Normal/Attack** của UNSW-NB15. Hai tập TRAIN và TEST chính thức được giữ riêng; các mô hình được lựa chọn từ quá trình development trên TRAIN và đánh giá cuối bằng cấu hình đã khóa. Nghiên cứu không tuyên bố phát triển detector đa lớp hoặc kiểm nghiệm trên dữ liệu triển khai độc lập.

Một giả định cần kiểm tra là liệu việc có nhiều base learners khác nhau và sai số bổ sung có thực sự đem lại cải thiện tổng thể so với một mô hình đơn mạnh, hay chỉ làm thay đổi đánh đổi giữa báo động giả (FP) và tấn công bỏ sót (FN). Ngoài chất lượng dự đoán, nghiên cứu quan tâm đến chi phí huấn luyện và suy luận cùng tác động của lựa chọn đặc trưng. Đây là case study có kiểm toán trên một benchmark, không phải chứng minh tính ưu việt chung của Ensemble Learning.

### 1.1.3 Các vấn đề nghiên cứu

Để đánh giá chất lượng và giới hạn của các mô hình phát hiện xâm nhập, nghiên cứu tập trung vào năm vấn đề sau:

**RQ1 — Hiệu quả Ensemble:** Liệu ensemble có cải thiện *ổn định* so với mô hình học máy đơn trong một protocol đánh giá tương ứng? Điều kiện ổn định qua nhiều lần huấn luyện vẫn chưa được kiểm chứng.

**RQ2 — Đặc trưng và chi phí:** Các chiến lược Feature Selection liên quan thế nào đến hiệu năng phát hiện, nhận diện tấn công và chi phí của những pipeline đã nghiên cứu? Phân tích cuối chưa tách được tác động riêng của số feature.

**RQ3 — Sai số bổ sung:** Mức cải thiện quan sát có liên hệ thế nào với mẫu sai số bổ sung giữa các base learners? Bằng chứng hiện có chủ yếu mang tính mô tả, không thiết lập nhân quả.

**RQ4 — Độ nhạy protocol:** Thứ hạng và chất lượng mô hình thay đổi như thế nào khi xem xét riêng các mẫu không trùng vector với tập TRAIN?

**RQ5 phụ — Xử lý mất cân bằng:** Các phương án xử lý mất cân bằng có liên quan như thế nào đến Recall, Macro-F1 và số lượng tấn công bị bỏ sót?

Năm vấn đề trên được phân tích bằng giao thức thực nghiệm ở Chương 3 và các kết quả ở Chương 4.

### 1.1.4 Mục tiêu và đóng góp nghiên cứu

Phần nghiên cứu đã có bằng chứng gồm: (i) xây dựng và lưu quy trình đánh giá có official holdout; (ii) đối chiếu Random Forest với Stacking, kèm Diversity/OOF và cả kết quả Voting không thuận lợi; (iii) phân tích đánh đổi hiệu năng–chi phí của hai track feature; (iv) đánh giá Macro-F1, MCC, FPR, FNR và chênh lệch theo cặp; (v) phân tích chi tiết sai số FP/FN và attack-family trong phạm vi nhị phân.

Các kết quả đó có thể có giá trị thực nghiệm và phương pháp luận trong phạm vi một case study; *không* đủ cơ sở để khẳng định một thuật toán Ensemble Learning mới, ưu thế tổng thể có ý nghĩa thống kê, hoặc khả năng khái quát ngoài UNSW-NB15. Phần đối chiếu chi tiết với prior work được giới hạn trong những nguồn đã có bằng chứng đọc và kiểm tra metadata; chưa phải tổng quan hệ thống đầy đủ của lĩnh vực.

### 1.1.5 Bố cục báo cáo

Chương 1 trình bày cơ sở lý thuyết và các hướng nghiên cứu liên quan. Chương 2 giới thiệu dữ liệu và quy trình tiền xử lý. Chương 3 mô tả mô hình và cách thực hiện thí nghiệm. Chương 4 phân tích kết quả huấn luyện và kiểm thử. Chương 5 thảo luận về ý nghĩa, hạn chế và hướng phát triển của nghiên cứu.

## 1.2 Các thuật toán học máy và phương pháp kết hợp

### 1.2.1 Phát hiện xâm nhập dựa trên đặc trưng luồng mạng

Hệ thống phát hiện xâm nhập mạng (NIDS) phân tích các quan sát về lưu lượng để phân biệt hoạt động bình thường và hoạt động có dấu hiệu tấn công. Một flow có thể được mô tả bằng giao thức, trạng thái kết nối, số gói, lượng byte, thời lượng, thông lượng và các thống kê thời gian. Những biến này làm dữ liệu có thể biểu diễn bằng bảng để áp dụng học máy, nhưng không chứa mọi thông tin của payload hoặc ngữ cảnh vận hành.

Trong báo cáo này, đơn vị dự đoán là một *dòng dữ liệu UNSW-NB15*. Mỗi dòng gồm vector $x = (x_1, \ldots, x_p)$ và nhãn $y \in \{0, 1\}$, trong đó $0$ là Normal và $1$ là Attack. Đây chưa phải một quyết định theo session hay một xác nhận của chuyên gia về sự cố thực tế. Biến `attack_cat` được giữ để phân tích lỗi theo nhãn thật sau kiểm thử, chứ không phải mục tiêu đã chứng minh của một bộ phân loại đa lớp.

#### 1.2.1.1 Quy trình biến đổi và leakage

Dữ liệu đầu vào có thể có biến số và biến phân loại, cần xử lý thiếu, mã hóa và chuẩn hóa tương ứng. Một nguyên tắc phương pháp quan trọng là mọi tham số học được từ dữ liệu, như thống kê chuẩn hóa, danh mục encoding hoặc cấu hình Feature Selection, phải được tính từ tập huấn luyện được phép dùng trong từng bước validation rồi áp dụng cho tập còn lại. `Pipeline` hỗ trợ quản lý chuỗi thao tác nhưng không thể tự loại trừ mọi vấn đề do quan sát quá giống nhau giữa các fold hoặc do chọn feature trước outer CV.

Độc lập ở cấp dòng và độc lập ở cấp phiên là hai giả định khác nhau. Nhiều flow có thể chia sẻ host, thời gian, dịch vụ hoặc cách tạo lưu lượng. Nếu chỉ chia ngẫu nhiên ở cấp dòng, điểm test hoặc validation có thể cao do hai phần chứa những mẫu tương tự. Ngược lại, việc phát hiện vector

trùng cũng không tự chứng minh hai dòng là cùng một phiên. Do đó nghiên cứu kiểm tra overlap theo định nghĩa rõ ràng và giữ nguyên giới hạn về nguồn gốc traffic.

#### 1.2.1.2 Sai số của bộ phát hiện

False positive (FP) là Normal bị báo Attack, làm tăng công việc xác minh cảnh báo; false negative (FN) là Attack bị trả về Normal, có thể làm bỏ sót sự kiện cần chú ý. Giá trị chi phí của FP/FN tùy môi trường triển khai và chưa được đo trong đề tài, nên không thể giả định một lỗi bỏ sót có giá trị đúng bằng một báo động giả. Việc đọc riêng FPR và FNR giúp trình bày đánh đổi này minh bạch hơn một chỉ số Accuracy duy nhất.

### 1.2.2 Mô hình Logistic Regression

Logistic Regression là mô hình tuyến tính xác suất. Đối với phân loại nhị phân, giá trị dự đoán dương có thể viết:

$$\widehat{p}(y = 1 \mid x) = \sigma(w^\top x + b), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}. \tag{1.1}$$

Một ngưỡng biến xác suất thành nhãn; threshold không nhất thiết phải bằng 0,5 trong mọi ứng dụng, nhưng nghiên cứu cuối đã khóa tại 0,5 trước official TEST. Điều chuẩn trong Logistic Regression kiểm soát độ lớn hệ số để hạn chế khớp quá mức. Đối với dữ liệu NIDS có quan hệ phi tuyến phức tạp, một mô hình tuyến tính có thể thiếu năng lực biểu diễn so với các mô hình cây, nhưng tính khác nhau của bề mặt quyết định lại có thể tạo dạng sai số bổ sung trong ensemble.

Trong chuỗi thực nghiệm, Logistic Regression được xem xét ở tầng base và meta. Vai trò này không chứng minh LR riêng lẻ tối ưu; sự hữu ích phải quan sát qua OOF predictions, độ đa dạng lỗi, và hiệu quả cuối trong protocol thống nhất. Nếu chỉ xét tập TEST rồi lựa chọn lại thành viên có chỉ số tốt nhất thì sẽ phá vỡ ranh giới đánh giá đã khóa.

### 1.2.3 Decision Tree và Random Forest

#### 1.2.3.1 Decision Tree

Decision Tree chia dữ liệu bằng các điều kiện theo biến và ngưỡng. Một thước đo mức hỗn tạp của nút là Gini:

$$G(D) = 1 - \sum_{k=0}^{1} p_k^2, \tag{1.2}$$

với $p_k$ là tỷ trọng lớp $k$ tại nút. Cây có thể biểu diễn điều kiện phi tuyến và tương tác giữa các đặc trưng, nhưng cây quá sâu dễ học các chi tiết riêng của TRAIN. Những siêu tham số như độ sâu tối đa, số quan sát tối thiểu ở lá hoặc số đặc trưng được xét tại mỗi lần tách có thể kiểm soát độ phức tạp.

Decision Tree không nhất thiết có độ chính xác tổng thể cao bằng Random Forest. Khi nó được chọn vào Stacking, lý do phương pháp hợp lệ là kiểm tra liệu một mô hình có cấu trúc sai số khác biệt có đóng góp hiệu quả hay không, thay vì giả định mô hình yếu kết hợp với mô hình mạnh luôn làm kết quả tốt hơn.

#### 1.2.3.2 Random Forest

Random Forest kết hợp nhiều cây được fit với tính ngẫu nhiên trong lấy mẫu và lựa chọn feature. Một mô tả của xác suất dự đoán là:

$$\widehat{p}_{\mathrm{RF}}(x) = \frac{1}{T} \sum_{t=1}^{T} \widehat{p}_t(y = 1 \mid x). \tag{1.3}$$

Tăng số cây thường đòi hỏi thêm thời gian train, suy luận và bộ nhớ. Tuy vậy, sự thay đổi hiệu năng không tuyến tính theo số cây, và việc tăng mô hình không bảo đảm vượt một mô hình ít cây hơn trên dữ liệu cụ thể. Trong cấu hình cuối RF-42 có 300 cây, còn RF-17 có 150 cây, kích thước lá cũng khác; mọi kết luận về riêng Feature Selection phải tránh so sánh này như một đối chứng chỉ thay số feature.

### 1.2.4 Voting, Stacking và sai số bổ sung

#### 1.2.4.1 Hard voting và weighted soft voting

Hard voting chọn nhãn theo số thành viên bình chọn [10, 5]. Weighted soft voting tổng hợp xác suất từ các model:

$$\widehat{p}_{\text{vote}}(x) = \sum_{m=1}^{M} w_m \widehat{p}_m(x), \quad w_m \geq 0, \quad \sum_{m=1}^{M} w_m = 1. \tag{1.4}$$

Trọng số dựa vào một tập validation riêng có thể điều chỉnh ưu tiên thành viên, nhưng chỉ số chất lượng cá nhân không nhất thiết dự báo đóng góp trong ensemble. Nếu tất cả base learners sai trên các dòng giống nhau, lấy trung bình dự đoán không có cơ chế sửa những lỗi chung ấy. Do đó diversity là biến quan sát có ý nghĩa, chứ không phải bằng chứng bắt buộc cho superiority.

#### 1.2.4.2 Out-of-fold training của Stacking

Stacking sử dụng một meta learner để học ánh xạ từ dự đoán của các base learners sang kết quả cuối [11]. Nếu dùng dự đoán trên chính tập fit của base learners để train meta, tầng meta có thể nhận đầu vào quá lạc quan. Out-of-fold (OOF) giảm vấn đề này: ở mỗi fold, base learner chỉ fit trên các fold khác và tạo xác suất cho fold hiện hành. Ghép lại cho mỗi dòng huấn luyện một dự đoán chưa được base learner fit trực tiếp trên dòng đó:

$$Z_{i,m} = \widehat{p}_m^{(-k(i))}(x_i), \qquad \widehat{p}_{\text{stack}}(x) = g\left(\widehat{p}_1(x), \ldots, \widehat{p}_M(x)\right). \tag{1.5}$$

Mô hình meta trong Stacking-42 là Logistic Regression. Trong suy luận cuối, các base learners được refit trên TRAIN được phép rồi đưa xác suất mới qua meta learner. Tuy nhiên, một Stacking dùng OOF không có nghĩa mọi bước chọn feature, tuning meta và lựa chọn mô hình đã được đưa vào nested CV hoàn toàn. Trong nghiên cứu này, meta tuning chưa fully nested và tập stable features được chọn trên official TRAIN trước development CV.

#### 1.2.4.3 Double-fault, error correlation và oracle

Double-fault đo tỷ lệ cùng sai của hai bộ phân loại, error correlation mô tả mức liên hệ giữa các biến chỉ báo lỗi, còn oracle giả định có thể chọn đúng đầu ra của một base model bất kỳ trên mỗi mẫu. Oracle là cận mô tả dưới thông tin nhãn thật, không phải thuật toán dự đoán có thể vận hành trực




**Hình 1.1.** Sơ đồ nguyên lý Stacking/OOF và ranh giới official TEST. Hình chỉ minh họa giao thức, không chứng minh nested validation đầy đủ.

tiếp. Những chỉ số này cho biết các base learners có thể bổ sung nhau ở đâu, nhưng không trả lời việc meta learner có thực sự học được quy tắc kết hợp đúng hay không. Kết quả voting không thuận lợi trong development vẫn phải được giữ lại để tránh thiên lệch chỉ báo cáo phương án tốt.

### 1.2.5 Các chiến lược Feature Selection

Filter selection sử dụng phép đo thống kê để xếp hạng biến; wrapper selection đánh giá trực tiếp các tập con thông qua mô hình; embedded selection khai thác cơ chế lựa chọn trong khi fit [13, 7]. Các phương pháp có ưu nhược điểm khác nhau về chi phí, tương tác biến và thiên lệch theo model. Tính ổn định của feature được chọn qua nhiều lần lặp giúp hạn chế phụ thuộc một phép chia cụ thể, nhưng không chứng minh loại bỏ biến ít quan trọng luôn cải thiện generalization.

Một phép đo gần bằng nhau của RF-17 và RF-42 không cho phép suy rằng 25 feature bị bỏ đều vô dụng. Mục tiêu của việc giảm feature trong đề tài là khảo sát một *đánh đổi giữa chất lượng và tài nguyên* của hai pipeline cụ thể. Muốn quy kết quả cho riêng số feature phải giữ cố định mọi thành phần khác của RF và lồng lựa chọn feature trong outer folds.

### 1.2.6 Các chỉ số đánh giá và diễn giải thống kê

#### 1.2.6.1 Precision, Recall, Macro-F1 và MCC

Với Attack là lớp dương:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \qquad \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \tag{1.6}$$

$$\text{F1} = \frac{2\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}}, \qquad \text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}, \tag{1.7}$$

$$\text{FNR} = \frac{\text{FN}}{\text{FN} + \text{TP}}, \qquad \text{Detection Rate} = 1 - \text{FNR}. \tag{1.8}$$

Macro-F1 lấy trung bình F1 hai lớp với trọng số bằng nhau. Weighted-F1 lấy trung bình theo support. MCC sử dụng toàn bộ ma trận nhầm lẫn:

$$\text{MCC} = \frac{\text{TPTN} - \text{FPFN}}{\sqrt{(\text{TP} + \text{FP})(\text{TP} + \text{FN})(\text{TN} + \text{FP})(\text{TN} + \text{FN})}}. \tag{1.9}$$

Macro-F1 khác MCC: Macro-F1 tổng hợp riêng chất lượng F1 của mỗi lớp, còn MCC đo tương quan giữa nhãn thật và nhãn dự đoán dựa trên cả bốn ô. Hai thước đo có thể xếp hạng hai mô hình khác nhau.

#### 1.2.6.2 Paired bootstrap và McNemar

Cùng một dòng TEST được dự đoán bởi hai model, do đó sai số của chúng có cấu trúc cặp. Paired bootstrap lấy mẫu lại chỉ số dòng, áp dụng chung cho hai mô hình và tính hiệu số metric trong mỗi lần lặp. CI 95% từ các lần lặp cho thấy bất định do các dòng benchmark đã quan sát, chứ không phải độ biến thiên giữa các lần train độc lập hoặc khi chuyển sang mạng khác.

McNemar kiểm tra số dòng A đúng/B sai so với A sai/B đúng. Đây là kiểm định trên *paired correctness*, không phải trực tiếp trên độ chênh lệch Macro-F1. Khi có nhiều phép so sánh, điều chỉnh Holm giới hạn rủi ro báo có ý nghĩa do thử nhiều giả thuyết. Các CI và phép kiểm định không sửa được tính phụ thuộc giữa các dòng flow; đó là giới hạn riêng về đơn vị lấy mẫu.

## 1.3 Các công trình nghiên cứu liên quan

### 1.3.1 Ensemble Learning trong NIDS

Tama và Lim khảo sát có hệ thống hướng Ensemble Learning cho Intrusion Detection và đặt trọng tâm vào base classifier, cách kết hợp và tính phụ thuộc của đánh giá theo benchmark [10]. Kết quả tổng quan này là cơ sở lựa chọn câu hỏi so sánh thực nghiệm, không thể thay bằng nhận định đơn giản rằng kết hợp nhiều classifier chắc chắn làm hiệu năng tăng.

Các cấu hình kết hợp đã được nghiên cứu theo nhiều hướng: soft voting có thành phần tìm cấu hình tự động [5], heterogeneous stacking với các base learners và meta learner được mô tả trong phần phương pháp của Thockchom và cộng sự [11], và hướng kết hợp lựa chọn đặc trưng với ensemble [3, 7]. Các nghiên cứu có phương pháp và tập dữ liệu khác nhau không được coi là baseline matched cho official UNSW-NB15 của đề tài. Việc tồn tại những công trình này giới hạn tuyên bố novelty: đóng góp được định vị ở kiểm toán case study, sự minh bạch về loại lỗi, bằng chứng cặp và chi phí, *không* phải tạo ra Stacking hay Feature Selection.

### 1.3.2 Feature Selection, chuẩn hóa và mất cân bằng

Việc giảm số đặc trưng có thể thay đổi chất lượng và chi phí của pipeline, nhưng phải tách việc chọn feature khỏi khâu đánh giá nếu muốn ước lượng hiệu ứng thật sự của chiến lược lựa chọn. Các nghiên cứu về filter-based Feature Selection trong IDS [13], đặc trưng và chuẩn hóa [12], cũng như embedded/correlation selection [7] là những nguồn đặt phạm vi cho câu hỏi RQ2, không phải bằng chứng rằng RF-17 của chúng tôi cải thiện nhờ *chỉ* loại feature.

Đối với dữ liệu mất cân bằng, nghiên cứu DUEN xem xét dynamic ensemble cùng thành phần xử lý phân bố lớp [8]. Do đề tài hiện không có so sánh matched resampling/no-resampling dưới cùng điều kiện, không thể kết luận các kỹ thuật cân bằng mẫu là vô ích hoặc có hiệu quả nhân quả từ những kết quả được lưu. Đây vẫn là giới hạn của RQ5.

### 1.3.3 Chất lượng dữ liệu và khả năng khái quát

Engelen và cộng sự phân tích lỗi và quá trình xử lý trong một bộ dữ liệu IDS khác (CICIDS2017) [4]; bài học phương pháp luận là cần kiểm toán pipeline và chất lượng dữ liệu, *không* chuyển nguyên các lỗi CICIDS2017

sang UNSW-NB15. Cantone và cộng sự nhấn mạnh sự khác biệt giữa đánh giá trong cùng một dataset và đánh giá cross-dataset [2]. Nghiên cứu của chúng tôi mới có official holdout cùng một phần novel-vector subset; đó không phải external validation hoặc phép đo generalization cross-dataset.

Khảo sát về các loại tấn công chưa biết, không điển hình và biến đổi hình thái [9] gợi ý yêu cầu đọc kết quả tổng thể trong mối liên hệ với các dạng tấn công khác nhau. Nhưng phân tích `attack_cat` ở đây là *nhóm nhãn thật của binary detector*, không phải đo khả năng dự đoán nhãn tấn công đa lớp hoặc unknown-attack deployment.

### 1.3.4 Khoảng trống bằng chứng và giới hạn tổng quan

So sánh ensemble cần báo cáo trung thực khả năng mô hình tốt hơn *hoặc không tốt hơn* baseline, mức thay đổi giữa FP và FN, quan hệ giữa diversity và gain, cùng chi phí của cấu hình đã chọn. Đối với UNSW-NB15, đề tài có saved official test, paired effects và phân tích hậu nghiệm, nhưng chưa có chứng cứ repeated training stability, nested FS ablation độc lập, temporal split, external validation và matched resampling. Do vậy những mục chưa có bằng chứng được trình bày như *khoảng thiếu của nghiên cứu này*, không được biến thành khẳng định rằng toàn bộ lĩnh vực chưa từng nghiên cứu chúng.

Các nhận xét tổng quan ở đây dựa trên những bài báo được trích dẫn trong danh mục tài liệu tham khảo; do khác biệt dữ liệu và giao thức, không sử dụng kết quả từ các nghiên cứu đó như đối chứng trực tiếp cho ba mô hình của đề tài.

### 1.3.5 Đối chiếu trực tiếp với các nghiên cứu gần phương pháp

Để định vị đóng góp thực nghiệm, chúng tôi đối chiếu giao thức của ba công trình gần nhất đã có bằng chứng đọc phần phương pháp: Thockchom và cộng sự [11], Nassreddine và cộng sự [7], Alsaffar và cộng sự [1]. Các công trình đều sử dụng thành phần lựa chọn đặc trưng và kết hợp bộ phân loại, do đó nghiên cứu này *không* tuyên bố tạo ra một thuật toán Stacking hay Feature Selection mới.

**Bảng 1.1.** Đối chiếu phạm vi phương pháp với công trình liên quan; khác giao thức thì không xếp hạng trực tiếp điểm số.

| Công trình | Dữ liệu và giao thức được ghi nhận | Thành phần/khả năng so sánh |
|---|---|---|
| Thockchom và cs. (2023) | Gồm UNSW-NB15, có mô tả random 80/20, không đồng nhất official holdout của đề tài | Chi-square và base GNB/DT/LR, meta SGD; đã có dự đoán base qua CV. |
| Nassreddine và cs. (2025) | NSL-KDD, CICIDS2017; không dùng official UNSW-NB15 TEST trong nghiên cứu này | Correlation/embedded selection, LR meta và SMOTE–TOMEK; chi tiết fold-local toàn chuỗi còn chưa xác minh. |
| Alsaffar và cs. (2024) | UNSW-NB15 và CICIDS2017; mô tả gộp partition rồi chia ngẫu nhiên 80/20 | MI–Boruta; RF/CatBoost/XGBoost với MLP meta. Đây là tiền lệ gần, không phải baseline có split khớp. |
| Nghiên cứu này | Official TRAIN 175 341 và TEST 82 332, split giữ nguyên; binary Normal/Attack | Stable17/42; RF và Stacking LR/DT/RF, LR meta; đánh giá paired CI, FP/FN, chi phí và novel-vector sensitivity. |

Điểm bổ sung có bằng chứng của đề tài là *case study đánh giá và kiểm toán* trên split chính thức, đối chiếu cùng mẫu các loại lỗi, mức bất định và chi phí, kể cả khi ensemble không vượt mô hình đơn mạnh. Đây là khác biệt *phạm vi đánh giá*, không chứng minh tính mới thuật toán, ưu thế trước số liệu của các bài khác, hay tổng quan đầy đủ toàn lĩnh vực. Phần Methods/results của ba nguồn được kiểm tra theo các đoạn đã tiếp cận; các chi tiết chưa xác minh không được suy diễn thành sai sót của công trình trước.

# Chương 2. DỮ LIỆU VÀ QUY TRÌNH TIỀN XỬ LÝ

## 2.1 Nguồn dữ liệu và quy mô bản ghi

UNSW-NB15 là bộ dữ liệu mô tả lưu lượng mạng dùng trong nghiên cứu phát hiện xâm nhập, được giới thiệu trong công bố của Moustafa và Slay [6]. Đề tài sử dụng chính xác hai file phân chia chính thức: 175 341 dòng TRAIN và 82 332 dòng TEST. Mục tiêu thực nghiệm được kiểm chứng là phân loại *Normal/Attack*; tên các nhóm tấn công không được sử dụng làm predictor trong mô hình binary.

**Bảng 2.1.** Phân bố hai lớp của các tập UNSW-NB15 chính thức.

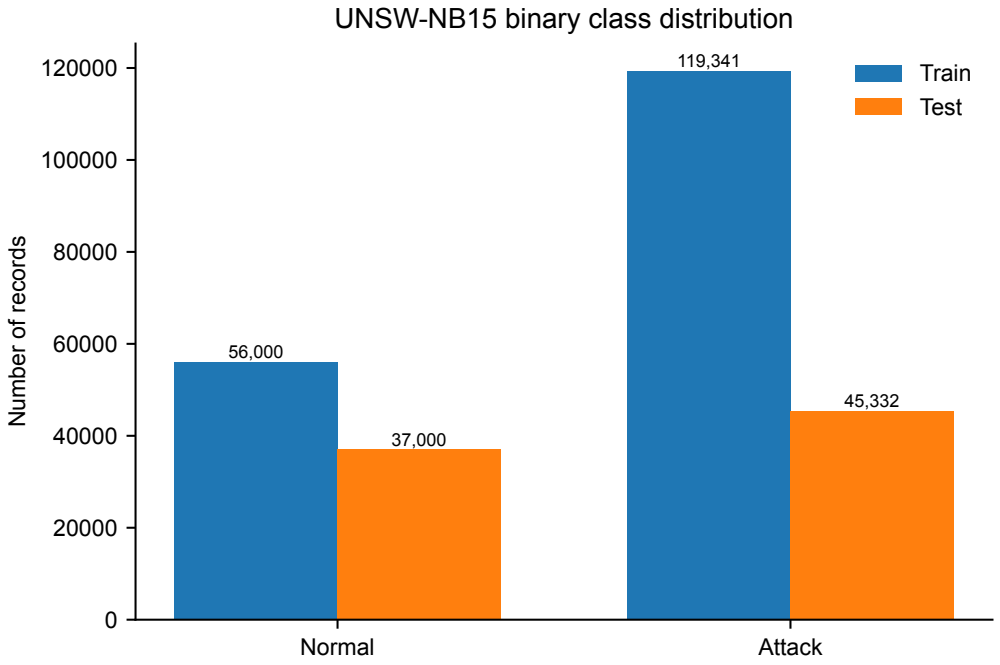
| Tập | Normal | Attack | Tổng | Attack (%) |
|---|---|---|---|---|
| TRAIN | 56 000 | 119 341 | 175 341 | 68.06 |
| TEST | 37 000 | 45 332 | 82 332 | 55.06 |

Sự khác biệt tỷ lệ Attack giữa TRAIN (68,06%) và TEST (55,06%) là một quan sát thực tế của dữ liệu chính thức, không phải tỷ lệ do nghiên cứu tự cân bằng lại. Điều này cho thấy tổng Accuracy và Weighted-F1 có thể chịu ảnh hưởng của cách phân bố lớp; đọc Macro-F1, MCC và chỉ số riêng từng lớp sẽ rõ ràng hơn khi so sánh các pipeline.

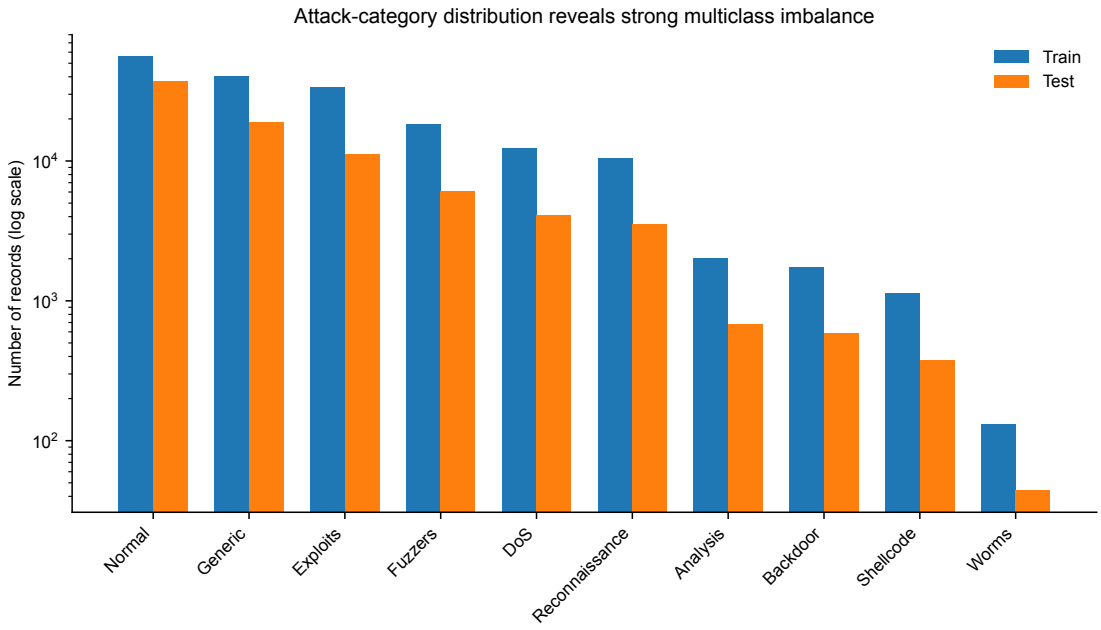
## 2.2 Các nhóm tấn công và mức độ chênh lệch

Ngoài lớp Normal, trường `attack_cat` chứa các họ tấn công như Analysis, Backdoor, DoS, Exploits, Fuzzers, Generic, Reconnaissance, Shellcode và Worms. Tại official TEST, Generic chiếm 18 871 dòng, Exploits 11 132 dòng và Fuzzers 6 062 dòng, trong khi Worms chỉ có 44 dòng. Quy mô hỗ trợ không đồng đều có thể làm độ chính xác theo từng nhóm biến động mạnh; một số đếm FN cần được đọc cùng mẫu số của chính nhóm Attack tương ứng.

Nhóm Attack ít mẫu không thể được coi là đã phát hiện tốt chỉ vì Accuracy nhị phân tổng thể cao. Một lớp hiếm có thể chỉ góp ít FN vào tổng nhưng lại có FNR cao trong chính lớp đó. Bởi vậy bước Error Analysis trong báo cáo phân nhóm các Attack thật, đồng thời tránh biến các khác biệt nhỏ thành khẳng định về toàn bộ dạng tấn công trong tự nhiên.




**Hình 2.1.** Phân bố nhãn Normal/Attack trong official TRAIN và TEST, biểu đồ phân bố lớp từ kết quả khảo sát dữ liệu.

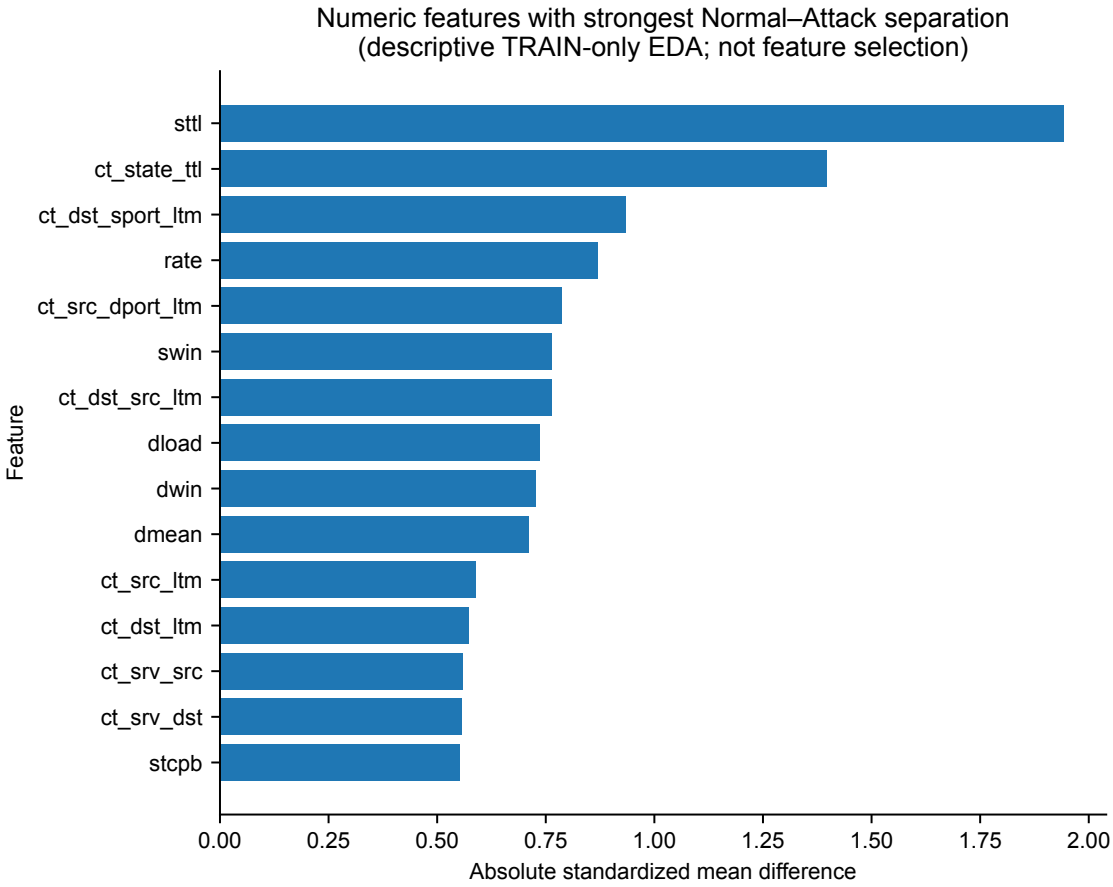



**Hình 2.2.** Số lượng bản ghi theo `attack_cat` của hai tập. Trong nghiên cứu hiện tại, đây là phân tích nhãn thật chứ không phải kết quả một mô hình multiclass.

## 2.3 Khảo sát thống kê các đặc trưng

EDA của TRAIN đã kiểm tra 39 biến số. Các tiêu chí thống kê dùng để khám phá không đồng nghĩa phép thử nhân quả. Chẳng hạn, standardized mean difference (SMD) giữa Normal và Attack lớn cho thấy trung bình hai nhóm có khác biệt tương đối theo độ phân tán, nhưng không có nghĩa một feature đơn lẻ là dấu hiệu tấn công đáng tin cậy trong mọi tổ hợp.

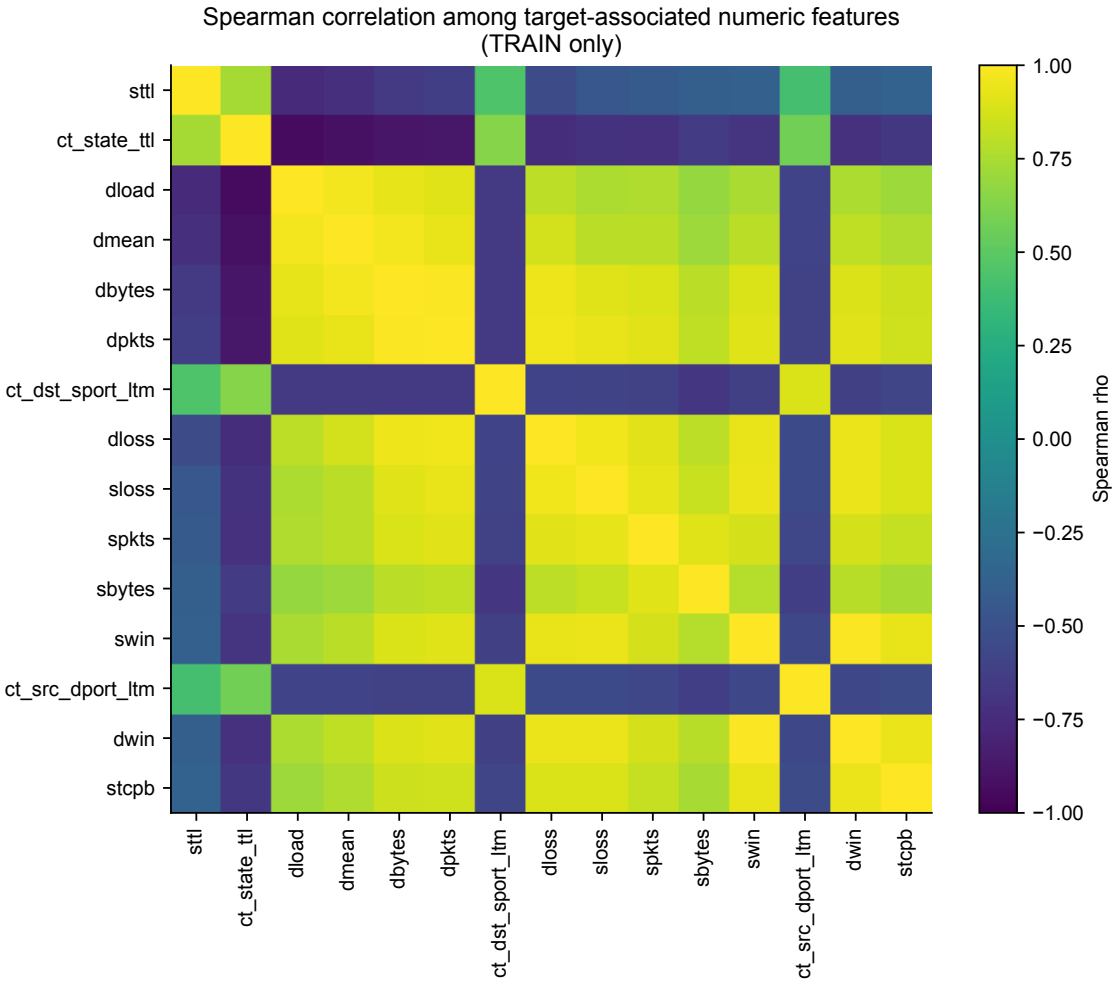
Các giá trị SMD lớn về độ lớn trong bảng EDA gồm `sttl` (1,9430), `ct_state_ttl` (1,3973), `ct_dst_sport_ltm` (0,9340), `rate` (0,8692), `ct_src_dport_ltm` (0,7853), cùng các biến có SMD âm như `swin` (-0,7636) và `dload` (-0,7346). Dấu và độ lớn của SMD phản ánh cách định nghĩa hai nhóm trong tập TRAIN; nó không thiết lập hướng tác động của feature lên xác suất bị tấn công.




**Hình 2.3.** Khảo sát mức tách biệt Normal/Attack ở một số feature số trên tập huấn luyện. Không dùng biểu đồ này để suy ra quan hệ nhân quả.

## 2.4 Tương quan giữa các đặc trưng

Trên tập huấn luyện, có 59 cặp feature số đạt $|\rho_{\text{Spearman}}| \geq 0,9$. Ví dụ, cặp `is_ftp_login` và `ct_ftp_cmd` có $\rho = 1,0000$; `trans_depth` và `ct_flw_http_mthd` có $\rho \approx 0,9996$; `tcprtt` và `synack` có $\rho \approx 0,9968$. Các cặp liên hệ mạnh có thể chứa thông tin trùng lắp trong tập mẫu, nhưng một hệ số tương quan đơn lẻ không cho biết mô hình cây sẽ phụ thuộc vào cặp đó tới mức nào.




**Hình 2.4.** Ma trận tương quan các feature số trên tập huấn luyện. Mối tương quan mạnh không tự chứng minh hai biến là tương đương về cơ chế hay có thể loại bỏ không làm mất thông tin.

Đối với bước lựa chọn đặc trưng, danh sách cặp tương quan có thể là một trong các nguồn bằng chứng để đề xuất feature candidates, nhưng lựa chọn chính thức còn cần kết hợp kết quả từ filter, embedded và wrapper. Điều quan trọng là giữ phần EDA mô tả tách khỏi quyết định lựa chọn trên validation, không lặng lẽ dùng thông tin từ official TEST để xếp hạng feature.

## 2.5 Kiểm toán overlap và các view đánh giá

Quy trình audit kiểm tra vector của 42 feature đã sử dụng cho phân loại nhị phân. Có 8 541 dòng official TEST trùng vector với ít nhất một dòng official TRAIN; phần còn lại gồm 73 791 dòng được đặt tên *novel-vector view*. Số 8 541 là *số dòng TEST*, không nhất thiết là số vector riêng biệt hay số session bị giao cắt. Các lớp có thể có giá trị feature giống nhau vì cách lượng hóa và tiền xử lý; vì vậy không được tuyên bố mọi trường hợp trùng vector đều là leakage cùng phiên.

**Bảng 2.2.** Hai góc nhìn đánh giá cùng thuộc official TEST đã lưu.

| View | Số dòng | Diễn giải hợp lệ |
|---|---|---|
| Official TEST | 82 332 | Tập holdout chính thức, dùng cho bảng hiệu năng cuối |
| Novel-vector subset | 73 791 | TEST sau khi bỏ dòng có vector 42 feature trùng với ít nhất một TRAIN vector |
| Overlap rows | 8 541 | TEST có vector feature trùng; không tự đồng nhất với cùng session |

Novel-vector view chỉ là một phép phân tích độ nhạy trong cùng bộ dữ liệu, không bảo đảm độc lập theo thời gian hoặc nguồn traffic. Do đó báo cáo trình bày riêng metric official và metric novel-vector, không thay official holdout bằng phần TEST được chọn sau khi quan sát kết quả. Một nghiên cứu đánh giá khả năng khái quát tốt hơn cần một benchmark ngoài hoặc group/temporal split được thiết kế trước, với định nghĩa đơn vị độc lập và quy trình pre-processing nhất quán.

## 2.6 Kết luận về đặc trưng của benchmark

UNSW-NB15 hỗ trợ một case study IDS nhị phân có quy mô vừa đủ cho đối chiếu nhiều pipeline và có nhãn Attack để phân tích sai số. Tuy nhiên, các chênh lệch lớp, tương quan feature mạnh, sự tồn tại của vector trùng và khả năng phụ thuộc giữa các dòng flow giới hạn phạm vi khái quát. Vì thế hiệu năng trên chính benchmark này được diễn giải dưới các điều kiện của phép đo, không tự chuyển thành khả năng phát hiện xâm nhập trên mạng triển khai thực tế.

# Chương 3. XÂY DỰNG MÔ HÌNH VÀ THIẾT KẾ THỰC NGHIỆM

## 3.1 Thiết kế và tập dữ liệu

Nghiên cứu đánh giá các pipeline học máy và Ensemble Learning cho phát hiện xâm nhập mạng trên bộ dữ liệu UNSW-NB15[6]. Nhiệm vụ đã được kiểm chứng trong chuỗi thí nghiệm cuối là **phân loại nhị phân**, với Normal = 0 và Attack = 1; các kết quả theo `attack_cat` sau đó chỉ là phân tích nhóm tấn công bị bỏ sót, *không phải mô hình đa lớp*. Mục tiêu là đánh giá performance, lỗi bổ sung, chi phí và độ bất định, không tuyên bố phát minh thuật toán Ensemble Learning mới.

Hai tập official của UNSW-NB15 được giữ nguyên: TRAIN có 175 341 dòng (56 000 Normal và 119 341 Attack), TEST có 82 332 dòng (37 000 Normal và 45 332 Attack). Không gộp rồi chia ngẫu nhiên lại hai tập này. Biến `id`, `label` và `attack_cat` bị loại khỏi predictors nhị phân; 42 biến còn lại tạo thành track toàn bộ đặc trưng. Bản kiểm toán dữ liệu ghi nhận 8 541 dòng TEST trùng vector 42 đặc trưng với ít nhất một dòng TRAIN; 73 791 dòng TEST còn lại tạo *novel-vector sensitivity view*. Đây vẫn là phần của chính official TEST, không phải external, temporal hoặc session split mới.

## 3.2 Feature selection và preprocessing

Track 17 feature được hình thành từ kết quả lựa chọn trên official TRAIN, cạnh track 42 biến gốc. Năm seed stability `11, 23, 42, 71, 101` được dùng để kiểm tra tần suất xuất hiện trong từng phương pháp; ngưỡng 0,60 tương ứng ít nhất 3/5 lượt, sau đó giữ biến đạt điều kiện trong ít nhất hai phương pháp. Đây là độ ổn định *của việc chọn biến*, không chứng minh độ ổn định chất lượng dự đoán qua các lần huấn luyện độc lập. Track stable17 đã khóa theo thứ tự:

`ct_srv_dst, ct_state_ttl, dload, dttl, proto, state, sttl, ct_dst_ltm, dmean, dwin, is_sm_ips_ports, rate, service, swin, ct_dst_sport_ltm, ct_dst_src_ltm, dbytes.`

Track RFECV riêng tạo 13 biến, không được hoán đổi với stable17. Cả hai kết quả đều nằm trong artifact feature selection đã lưu; không áp

dụng lựa chọn đặc trưng mới sau khi xem kết quả TEST. Biến phân loại `proto`, `service`, `state` được One-Hot Encoding với `handle_unknown=ignore`; đặc trưng số được đưa qua chuỗi preprocessing theo từng learner, với chuẩn hóa số cho Logistic Regression và không đánh đồng số cột one-hot với 17/42 feature *gốc*. Các phép biến đổi có tham số học được nằm trong `sklearn.Pipeline`, khớp mã thực nghiệm frozen. Một giới hạn bắt buộc là stable feature selection được thực hiện trên *toàn bộ official TRAIN trước development cross-validation*, không lặp hoàn toàn bên trong từng outer fold. Vì vậy điểm development CV có thể lạc quan hơn kết quả của quy trình feature selection nested thật. Chúng tôi không tuyên bố loại trừ mọi dạng leakage.

## 3.3 Các pipeline được khóa trước final evaluation

Ba cấu hình cuối và ngưỡng phân loại 0,5 được xác định trước bước đánh giá cuối trên tập TEST.

**Bảng 3.1.** Cấu hình pipeline cuối theo frozen manifest.

| Candidate | Cấu hình | Feature |
|---|---|---|
| RF-42 | Random Forest 300 cây, `max_features`=0.5, `min_samples_leaf`=1 | 42 |
| Stacking-42 | Base Logistic Regression ($C = 1$, liblinear), Decision Tree (leaf=2), RF như RF-42; meta Logistic Regression ($C = 0.5$, liblinear, class weight None), inner CV 3 folds và `passthrough`=False | 42 |
| RF-17 | Random Forest 150 cây, `max_features`=0.5, `min_samples_leaf`=2 | 17 |

Stacking sử dụng dự đoán *out-of-fold* của các base learners để huấn luyện meta learner, thay vì sử dụng thuần in-sample predictions của tầng base. Mã nguồn có inner `StratifiedKFold`; các seed ghi nhận là 42 cho thí nghiệm và 137 cho inner stacking. Việc dùng OOF giúp hạn chế một dạng overfitting tầng meta nhưng phần meta tuning chưa hoàn toàn nested, nên không bảo đảm development validation unbiased. Diversity và voting được xem xét trong development; kết quả voting không thuận lợi cũng là kết quả nghiên cứu cần báo cáo.

RF-17 khác RF-42 cả số feature *và* tham số Random Forest (số cây, kích thước lá), nên mọi chênh lệch giữa chúng là *pipeline-level performance–cost trade-off*, không phải ablation tách biệt nhân quả của số lượng đặc trưng.

## 3.4 Các bước triển khai và huấn luyện

Quá trình thực nghiệm được thực hiện bằng Python với thư viện `scikit-learn`. Đối với mỗi cấu hình, chương trình tiến hành thống nhất các bước sau:

1. Kiểm kê và xác minh hai tập official TRAIN/TEST theo manifest; trong bước chọn feature, development CV và khóa cấu hình, chỉ sử dụng official TRAIN. Cột `id`, `attack_cat`, `label` không làm predictor nhị phân; file TEST chỉ được đưa vào đánh giá sau freeze.
2. Xây dựng chuỗi tiền xử lý thích hợp với đặc trưng số và đặc trưng phân loại, bảo đảm tham số biến đổi chỉ được ước lượng từ phần dữ liệu huấn luyện được phép.
3. Huấn luyện các mô hình cơ sở; với Stacking, sử dụng dự đoán ngoài fold để xây dựng tập đầu vào cho bộ phân loại tầng kết hợp.
4. Lựa chọn và cố định cấu hình theo kết quả phát triển mô hình trên TRAIN. Sau đó huấn luyện lại bằng toàn bộ TRAIN và dự đoán trên official TEST với ngưỡng 0,5.
5. Tính confusion matrix, Precision, Recall, Macro-F1, MCC, FPR, FNR và thời gian thực thi; xuất dự đoán cùng các bảng chỉ số để phân tích đối chiếu.

Các bước này mô tả đúng trình tự triển khai. Mã nguồn Python đi kèm báo cáo là căn cứ để kiểm tra chi tiết thao tác tiền xử lý, đối tượng mô hình và lệnh đánh giá.

## 3.5 Final evaluation, uncertainty và sai số

Sau khi đóng băng cấu hình và threshold 0,5, các pipeline được huấn luyện trên official TRAIN và đánh giá cuối trên official TEST. Kết quả dự đoán và các chỉ số đánh giá được trình bày trong Chương 4. Không dùng TEST để chọn lại mô hình, tối ưu ngưỡng hay sửa feature set. Attack là positive class: $\mathrm{FPR} = \mathrm{FP}/(\mathrm{TN}+\mathrm{FP})$, $\mathrm{FNR} = \mathrm{FN}/(\mathrm{TP}+\mathrm{FN})$, Detection Rate $= 1 - \mathrm{FNR}$. Cùng với Macro-F1 và MCC, nghiên cứu còn lưu ROC-AUC và trường `pr_auc`; trường sau được mã nguồn tính bằng `average_precision_score`, vì vậy phải diễn giải là Average Precision (AP), không tự coi là phương pháp tích phân PR-AUC khác.

Chênh lệch metric giữa các model được phân tích bằng paired bootstrap 10 000 lượt với seed 20260928: các dự đoán của hai mô hình trên *cùng dòng* được ghép cặp, phân tầng theo nhãn thật Normal/Attack và giữ nguyên tổng số mẫu của từng lớp bằng resampling multinomial trên các mẫu hình dự đoán liên hợp. CI 95% là percentile interval cho từng chỉ số riêng, không phải simultaneous familywise-adjusted CI. Đơn vị biến thiên là các dòng benchmark có điều kiện trên số lượng hai lớp, *không* đại diện repeated-training variability, session/host độc lập hay độ bất định ngoài UNSW-NB15. McNemar exact so sánh *paired overall correctness*; hiệu chỉnh Holm thực hiện cho ba cặp model trong từng evaluation view (không phải mọi bảng CI/profile), và đây không phải kiểm định trực tiếp Macro-F1. Các phân tích lỗi theo `attack_cat`, `proto`, `state`, `sttl`, `dload` là mô tả hậu nghiệm; không dùng để suy ra quan hệ nhân quả hay tạo threshold mới.

## 3.6 Các giới hạn về tái lập và tính hợp lệ

Việc kiểm tra tính toàn vẹn dữ liệu, sự nhất quán giữa cấu hình và mã nguồn, cùng khả năng tính lại chỉ số từ dự đoán giúp tăng tính kiểm chứng của thí nghiệm. Môi trường thư viện của các mô hình lịch sử chưa được lưu đầy đủ, vì vậy chưa chứng minh *đồng nhất bitwise* với đối tượng đã tạo ra số liệu TEST. Tại checkpoint 17/10/2026, cả ba frozen candidates RF-17, RF-42, Stacking-42 đã được *tái dựng riêng* trên 175 341 dòng official TRAIN; các run reports ghi PASS và kiểm định artifact trên laptop tác giả xác nhận SHA-256, tải lại model, schema và khả năng dự đoán trên 16 dòng TRAIN (69/69 checks). Đây là artifact `RECONSTRUCTED_FULL_TRAIN`, *không phải* model lịch sử và *không* tái chứng minh điểm TEST lịch sử. Kết quả tái dựng có môi trường Python 3.11.9, scikit-learn 1.9.0 được ghi lại. Ranh giới này không được che bởi các thí nghiệm smoke trên tập con.

# Chương 4. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

## 4.1 Phạm vi đánh giá và cách đọc các chỉ số

Các kết quả trong chương này là các số liệu đã lưu của bài toán phát hiện xâm nhập nhị phân trên UNSW-NB15, với **Normal = 0** và **Attack = 1**. Tập huấn luyện chính thức có 175 341 dòng và tập kiểm thử chính thức có 82 332 dòng, gồm 37 000 Normal và 45 332 Attack. Ba pipeline được khóa trước đánh giá cuối là Random Forest 42 đặc trưng (RF-42), Stacking 42 đặc trưng (Stacking-42), và Random Forest 17 đặc trưng (RF-17). Tất cả sử dụng ngưỡng dự đoán nhị phân 0,5.

Các biến `id`, `label`, `attack_cat` không được dùng làm biến dự đoán của bài toán nhị phân. `attack_cat` chỉ được dùng để phân tích hậu nghiệm nhóm mẫu tấn công bị bỏ sót. Phần kết quả này *không* chứng minh khả năng nhận diện đa lớp.

Với Attack là lớp dương, ta có:

$$\text{FPR} = \frac{\text{FP}}{\text{TN} + \text{FP}}, \qquad \text{FNR} = \frac{\text{FN}}{\text{TP} + \text{FN}}, \qquad \text{Detection Rate} = 1 - \text{FNR}. \quad (4.1)$$

Macro-F1 là trung bình F1 hai lớp với trọng số bằng nhau; MCC phản ánh tương quan giữa dự đoán và nhãn trong toàn bộ confusion matrix. Do có đánh đổi giữa báo động giả và bỏ sót, không nên dùng Accuracy riêng lẻ để kết luận mô hình tốt hơn.

## 4.2 Kết quả trên official holdout

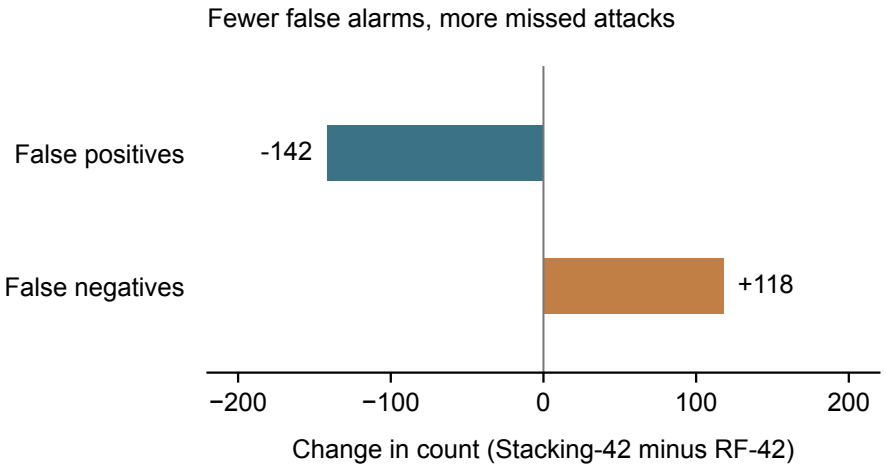
**Bảng 4.1.** Hiệu năng nhị phân của ba pipeline trên official TEST (82 332 mẫu; threshold 0,5). FPR và FNR tính theo phần trăm.

| Pipeline | Macro-F1 | MCC | FPR (%) | FNR (%) | FP | FN |
|---|---|---|---|---|---|---|
| RF-42 | 0.863343 | 0.750910 | 27.0351 | 1.6192 | 10003 | 734 |
| Stacking-42 | 0.863840 | 0.750497 | 26.6514 | 1.8795 | 9861 | 852 |
| RF-17 | 0.860673 | 0.746881 | 27.6324 | 1.5618 | 10224 | 708 |

Stacking-42 có Macro-F1 nhỉnh hơn RF-42 về mặt số học, nhưng MCC thấp hơn rất nhẹ. Quan trọng hơn, Stacking-42 giảm **142 FP** (10 003 xuống 9 861) đồng thời tăng **118 FN** (734 lên 852). Đây là sự dịch chuyển đánh đổi giữa hai loại lỗi; chưa có ma trận chi phí tác nghiệp để quy đổi hai thay

đổi này thành một lợi ích triển khai tổng thể.

RF-17 có Macro-F1 thấp hơn RF-42 khoảng 0,002670; đổi lại, thời gian và dung lượng mô hình lịch sử giảm đáng kể (Mục 4.4). RF-17 đồng thời sử dụng siêu tham số Random Forest khác RF-42, nên so sánh này là *đánh đổi giữa hai pipeline*, không phải thí nghiệm chỉ thay duy nhất số đặc trưng.




**Hình 4.1.** Chênh lệch số lượng lỗi Stacking-42 trừ RF-42 trên cùng official TEST: FP giảm 142 mẫu và FN tăng 118 mẫu. Số lượng quan sát trên benchmark cố định, không phải sai khác trung bình qua nhiều lần huấn luyện.

## 4.3 Khoảng tin cậy và kiểm định cặp

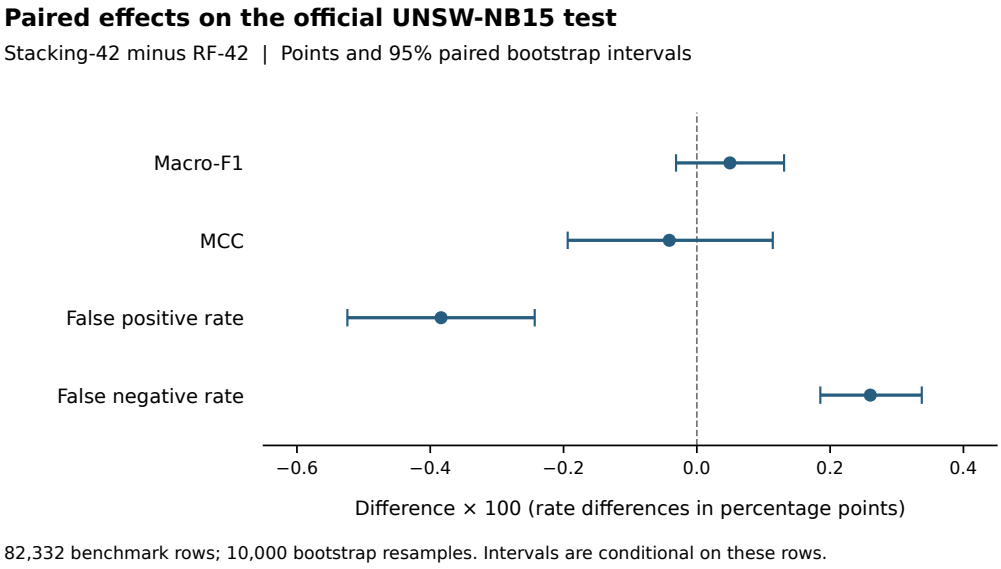
**Bảng 4.2.** Chênh lệch Stacking-42 trừ RF-42 và CI 95% paired bootstrap đã lưu; 10 000 lần lấy mẫu bootstrap từ các dòng benchmark. Đơn vị là độ chênh tuyệt đối trên thang 0–1.

| Chỉ số | Δ | CI dưới 95% | CI trên 95% |
|---|---|---|---|
| Macro-F1 | +0.000497 | -0.000312 | +0.001309 |
| MCC | -0.000413 | -0.001938 | +0.001140 |
| FPR | -0.003838 | -0.005243 | -0.002432 |
| FNR | +0.002603 | +0.001853 | +0.003375 |

Khoảng tin cậy của chênh lệch Macro-F1 và MCC chứa 0. Do đó, kết quả *không cung cấp bằng chứng đủ mạnh cho ưu thế tổng thể* của Stacking-42 so với RF-42 trên hai thước đo này; điều này *không* chứng minh hai mô hình tương đương thống kê. McNemar exact với hiệu chỉnh Holm trên *đúng/sai tổng thể của các cặp dự đoán* cho $p_{\text{Holm}} = 0.468377$ trong cùng phép so sánh; McNemar không phải kiểm định trực tiếp chênh lệch Macro-F1.

CI của FPR nằm hoàn toàn phía âm và CI của FNR nằm hoàn toàn phía dương. Các khoảng tin cậy này phản ánh biến động do lấy mẫu lại *các*

*dòng benchmark đã lưu*, không phải độ ổn định qua các lần huấn luyện độc lập, session độc lập hay dữ liệu ngoài bộ UNSW-NB15. Hình 4.2 mô tả trực quan các hiệu số cùng khoảng tin cậy 95%.




**Hình 4.2.** Bốn hiệu số Stacking-42 trừ RF-42 và CI 95% paired bootstrap đã lưu. Giá trị trục ngang là hiệu số nhân 100 (không phải phần trăm thay đổi tương đối). CI của Macro-F1 và MCC chứa 0; FPR giảm, FNR tăng.

## 4.4 Chi phí mô hình và số đặc trưng

**Bảng 4.3.** Chi phí được ghi nhận trong lần chạy lịch sử. Kích thước sử dụng đơn vị MiB (byte chia $1024^2$), không phải MB thập phân.

| Pipeline | Số feature | Train (s) | Inference (ms/mẫu) | Size (MiB) |
|---|---|---|---|---|
| RF-42 | 42 | 371.244 | 0.008679 | 205.490 |
| Stacking-42 | 42 | 980.170 | 0.012445 | 206.216 |
| RF-17 | 17 | 57.255 | 0.003562 | 105.044 |

Trong các số đo đã lưu, thời gian huấn luyện của RF-42 gấp khoảng 6,48 lần RF-17, và kích thước mô hình ước lượng của RF-17 thấp hơn khoảng 48,88% so với RF-42. Các số liệu chỉ phản ánh *chi phí quan sát của những cấu hình cụ thể trong lần chạy lịch sử*; chưa có phân bố thời gian qua nhiều lần huấn luyện và chưa có cơ sở dự báo thời gian trên thiết bị triển khai. Môi trường Python và thư viện tại thời điểm huấn luyện gốc chưa được xác định trực tiếp. Trường kích thước biểu diễn kết quả ước lượng serialize trong lần chạy, không chứng minh file mô hình cuối hiện tồn tại trên ổ đĩa.

## 4.5 Phân tích lỗi theo họ tấn công

**Bảng 4.4.** Số mẫu Attack thực bị dự đoán là Normal, phân nhóm theo `attack_cat`; đây không phải đánh giá multiclass.

| Nhóm Attack | Số mẫu | FN RF-42 | FN Stack-42 | Δ FN |
|---|---|---|---|---|
| Fuzzers | 6062 | 621 | 754 | +133 |
| Generic | 18871 | 57 | 14 | -43 |
| Nhóm còn lại | 20399 | 56 | 84 | +28 |
| Tổng Attack | 45332 | 734 | 852 | +118 |

Trên Fuzzers, Stacking-42 bỏ sót thêm 133 mẫu so với RF-42; trên Generic, Stacking-42 bỏ sót ít hơn 43 mẫu. Các đếm này mô tả tác động *không đồng đều giữa các nhóm nhãn thật*, nhưng không chỉ ra cơ chế nhân quả của `sttl`, `proto` hay các feature khác. Những nhóm rất ít mẫu không cho phép khái quát chắc chắn về mọi tấn công ngoài benchmark. Tất cả phân tích lỗi được thực hiện hậu nghiệm trên prediction đã khóa, không được dùng để chỉnh ngưỡng dự đoán.

## 4.6 Kiểm tra độ nhạy trên nhóm vector chưa trùng

**Bảng 4.5.** Macro-F1 trên official TEST và phần novel-vector của cùng official TEST. Novel-vector *không* phải bộ dữ liệu kiểm thử độc lập.

| Pipeline | Official TEST ($n = 82332$) | Novel-vector ($n = 73791$) |
|---|---|---|
| RF-42 | 0.863343 | 0.857473 |
| Stacking-42 | 0.863840 | 0.858125 |
| RF-17 | 0.860673 | 0.855723 |

Cả ba pipeline có Macro-F1 thấp hơn trên nhóm novel-vector. Tập con này được xác định bằng cách loại những dòng TEST có vector 42 đặc trưng trùng với ít nhất một vector TRAIN; 8 541 dòng TEST thuộc nhóm overlap theo cách định nghĩa này. Đây là một *sensitivity analysis* trong cùng benchmark, không thay cho đánh giá external, temporal, day hoặc session split. Vì vậy, câu hỏi RQ4 về độ nhạy với *split protocol* chưa được trả lời đầy đủ.

## 4.7 Bằng chứng development: Voting, OOF và diversity

Tất cả số liệu trong Bảng 4.6 là *pooled out-of-fold* trên official TRAIN với outer `StratifiedKFold` ba fold (seed 42), và inner Stacking ba fold (seed 137). Đây là dữ liệu development trước final tuning, không phải chỉ số official TEST; feature selection trước outer CV còn nguy cơ lạc quan.

**Bảng 4.6.** Development pooled OOF trên track 42 biến. FPR/FNR tính bằng %; giữ cả Voting bất lợi.

| Cấu hình development | Macro-F1 | MCC | FPR (%) | FNR (%) |
|---|---|---|---|---|
| Random Forest | 0.950387 | 0.901580 | 9.4214 | 1.8217 |
| Hard Voting (LR/DT/RF) | 0.947325 | 0.896278 | 10.9357 | 1.4530 |
| Soft Voting (LR/DT/RF) | 0.946758 | 0.894101 | 9.5232 | 2.2457 |
| Stacking (LR/DT/RF) | 0.951484 | 0.903201 | 8.0536 | 2.3688 |

Stacking cao hơn RF đơn khoảng $0.001096$ Macro-F1 và $0.001621$ MCC ở development nhưng đồng thời FPR giảm 1.368 điểm phần trăm và FNR tăng 0.547 điểm phần trăm. Hard/Soft Voting có Macro-F1 thấp hơn RF. Điều này không chứng minh một ensemble thắng ổn định hoặc giải thích nhân quả một cơ chế.

Các bản ghi diversity OOF cho track 42 cho thấy LR/RF có double-fault $0.030814$, error correlation $0.563855$; DT/RF có double-fault $0.025345$, error correlation $0.498922$. Các base learner không hoàn toàn trùng lỗi; song pairwise oracle/correlation không bảo đảm Voting hoặc meta learner tận dụng phần bù lỗi đó.

## 4.8 Trả lời cụ thể năm câu hỏi nghiên cứu

### 4.8.1 RQ1: Ensemble có cải thiện ổn định so với mô hình đơn?

**Trả lời: chưa có cơ sở kết luận cải thiện ổn định; trên official TEST chưa xác nhận superiority tổng thể của Stacking.** Kết quả development Stacking nhỉnh hơn RF ($0.951484$ so với $0.950387$ Macro-F1), nhưng trên official TEST Stacking-42 chỉ tăng $0.000497$ Macro-F1 và giảm $0.000413$ MCC so với RF-42. CI 95% paired bootstrap của hai hiệu số lần lượt $[-0.000312; 0.001309]$ và $[-0.001938; 0.001140]$ đều chứa 0. Kiểm định McNemar exact được Holm điều chỉnh có $p = 0.468377$ trên tính đúng tổng thể; không chứng minh hai pipeline bằng nhau về mặt thống kê. Trên 82 332 dòng TEST, Stacking giảm 142 FP nhưng tăng 118 FN. Một lượt

fitting mỗi candidate và bootstrap trên những dòng đã dự đoán không đo biến thiên theo các lần huấn luyện độc lập. Ba model full TRAIN được tái dựng P15 không phải một repeated-training study. Vì vậy phần ổn định qua seed/run là *chưa kiểm chứng*, khác với khẳng định ensemble không có ích trong mọi hoàn cảnh.

### 4.8.2 RQ2: Feature Selection thay đổi chất lượng và chi phí ra sao?

**Trả lời: hai pipeline thể hiện trade-off định lượng nhưng không thể quy nguyên nhân riêng cho giảm số feature.** Track stable17 được chọn trên TRAIN với 5 seed và quy tắc ổn định 3/5 trong tối thiểu hai phương pháp; đó không là bằng chứng ổn định hiệu năng dự đoán. Official TEST: RF-17 đạt Macro-F1 0.860673 và MCC 0.746881, so với RF-42 lần lượt 0.863343 và 0.750910. RF-17 có 708 FN (so với 734) nhưng 10 224 FP (so với 10 003). Trong số đo lịch sử, RF-17 train 57.255 giây, kích thước ước lượng 105.044 MiB; RF-42 train 371.244 giây, 205.490 MiB. RF-42 mất thời gian train khoảng 6.48 lần và RF-17 nhỏ hơn khoảng 48.88%. Tuy nhiên RF-17 còn dùng 150 cây và leaf tối thiểu 2, RF-42 dùng 300 cây và leaf tối thiểu 1; đây là so sánh cấu hình, *không* là matched feature-count ablation. FS trên toàn TRAIN trước development CV cũng có selection optimism risk.

### 4.8.3 RQ3: Sai số bổ sung có liên hệ với kết quả Ensemble?

**Trả lời: có sai số bổ sung ở base learners nhưng quan hệ với gain chỉ mang tính mô tả.** Trong development, error correlation DT/RF là 0.498922, LR/RF là 0.563855; double-fault của hai cặp lần lượt 0.025345 và 0.030814. Hard Voting (0.947325) và Soft Voting (0.946758) có Macro-F1 thấp hơn RF (0.950387), Stacking (0.951484) chỉ nhỉnh hơn; diversity quan sát không tự bảo đảm ensemble cải thiện. Trên official TEST có 71 104 mẫu cả RF-42 và Stacking-42 đúng; 10 222 mẫu cùng sai; 491 mẫu RF đúng/Stack sai; 515 mẫu RF sai/Stack đúng. Đây là paired correctness của *final models*, không phải diversity giữa các base learners ở development và không xác lập cơ chế sửa lỗi nhân quả.

### 4.8.4 RQ4: Mô hình thay đổi khi loại vector TEST trùng TRAIN?

**Trả lời: Macro-F1 giảm ở cả ba pipeline, nhưng thứ hạng không đảo trong hai view được lưu.** Trong 82 332 dòng official TEST có 8 541 dòng trùng vector 42 feature với TRAIN; novel-vector view còn 73 791 dòng.

**Bảng 4.7.** RQ4: Macro-F1 trong cùng official TEST, không phải validation độc lập.

| Pipeline | Official | Novel-vector | Chênh lệch |
|---|---|---|---|
| Stacking-42 | 0.863840 | 0.858125 | −0.005715 |
| RF-42 | 0.863343 | 0.857473 | −0.005870 |
| RF-17 | 0.860673 | 0.855723 | −0.004950 |

Stacking-42 vẫn đứng trên RF-42 và RF-17 theo Macro-F1 nhưng khoảng cách nhỏ. Đây là phân tích sensitivity theo exact-vector overlap trong cùng TEST, không chứng minh temporal/host/session split hoặc external generalization.

### 4.8.5 RQ5: Xử lý mất cân bằng ảnh hưởng lỗi như thế nào?

**Trả lời: quan sát được phân bố lớp và đánh đổi lỗi; tác động nhân quả riêng của class weighting hoặc resampling chưa được xác định.** Official TRAIN có 56 000 Normal (31.94%) và 119 341 Attack (68.06%); official TEST có 37 000 Normal (44.94%) và 45 332 Attack (55.06%). Dù Attack là đa số trong TRAIN, các *attack families* có hỗ trợ rất khác nhau. Trên official TEST, RF-42 có FPR 27.0351%, FNR 1.6192%; Stacking-42 lần lượt 26.6514%, 1.8795%; RF-17 là 27.6324%, 1.5618%. Trong tuning có so sánh `class_weight=None/balanced` cho meta learner, nhưng Stacking cuối chọn None. Không có thí nghiệm matched weight/no-weight hoặc SMOTE/no-SMOTE cố định các điều kiện còn lại, nên không thể gán thay đổi Recall, Macro-F1 hay FNR cho biện pháp cân bằng lớp. Đây là giới hạn của RQ5; kiểm tra nhân quả cần protocol mới trên training folds, không retune TEST lịch sử.

**Tóm lược kết luận RQ1–RQ5:** RQ1 chưa chứng minh stable superiority; RQ2 xác lập trade-off của hai cấu hình, không cô lập feature count; RQ3 cho thấy lỗi bổ sung nhưng không xác lập cơ chế; RQ4 xác lập độ nhạy và thứ hạng trên novel-vector subset; RQ5 ghi nhận lỗi/phân bố nhưng chưa có đối chứng class-imbalance. Đây là các câu trả lời đúng *phạm vi bằng chứng hiện có*, không phải năm giả thuyết đều được xác nhận.

# Chương 5. THẢO LUẬN VÀ HƯỚNG PHÁT TRIỂN

## 5.1 Tại sao điểm số tổng thể chưa đủ

Trong NIDS, việc chọn một pipeline chỉ theo Macro-F1 hoặc Accuracy có thể dẫn tới hiểu nhầm mục tiêu sử dụng. Official TEST chứa 37 000 dòng Normal và 45 332 dòng Attack. Với cùng tập này, Stacking-42 giảm số FP từ 10 003 xuống 9 861 nhưng tăng FN từ 734 lên 852 so với RF-42. Nếu người vận hành đặt chi phí FN lớn hơn nhiều chi phí FP thì đánh đổi này có thể không mong muốn; trong một môi trường quá tải bởi cảnh báo giả, việc giảm FP lại có giá trị riêng. Tuy nhiên, nghiên cứu không đo chi phí thực tế nên chỉ mô tả đánh đổi, không gọi một pipeline là tốt nhất cho mọi tình huống.

Số ít trường hợp Stacking sửa lỗi của RF và số trường hợp ngược lại còn cho phép nhìn sâu hơn vào kết luận thống kê. Trong bảng paired correctness có 71 104 mẫu hai mô hình đều đúng, 10 222 mẫu đều sai, 491 mẫu RF-42 đúng nhưng Stacking-42 sai và 515 mẫu Stacking-42 đúng nhưng RF-42 sai. Sự cân bằng tương đối giữa hai ô sai khác này giải thích vì sao kiểm định về *tính đúng tổng thể* không cho thấy một ưu thế rõ, dù FP/FN theo từng lớp đổi theo những hướng khác nhau.

**Bảng 5.1.** Tính đúng/sai của RF-42 và Stacking-42 theo từng cặp dự đoán, official TEST.

| | Stacking đúng | Stacking sai |
|---|---|---|
| RF đúng | 71 104 | 491 |
| RF sai | 515 | 10 222 |

Các ô tính đúng/sai chỉ chứa nhãn đúng/sai tổng thể, trong khi confusion matrix còn phân biệt Normal/Attack. Vì vậy McNemar về hai ô discordant không thể thay thế kiểm tra FPR/FNR hoặc Macro-F1. Việc một phép kiểm định không bác bỏ giả thuyết không đồng nghĩa chứng minh hai mô hình tương đương; nó chỉ phản ánh sức mạnh bằng chứng trong phép thử và dữ liệu được dùng.

## 5.2 Sai số theo nhóm tấn công

Trên 6 062 mẫu Fuzzers thật, RF-42 bỏ sót 621 trong khi Stacking-42 bỏ sót 754, tức Stacking tăng 133 FN. Trên Generic có 18 871 mẫu, RF-42 bỏ sót 57 và Stacking-42 bỏ sót 14, nghĩa là Stacking giảm 43 FN. Hai thay đổi ngược hướng cho thấy một metric gộp toàn bộ Attack có thể che ảnh hưởng không đồng đều giữa các nhóm.

Vì mô hình được huấn luyện cho binary Normal/Attack, đây là phân nhóm những nhãn thật phục vụ phân tích hậu nghiệm. Không được diễn giải các đếm FN thành bảng multiclass accuracy. Đặc trưng `sttl`, `proto`, `state` và các biến khác có thể đồng xuất hiện với mẫu bị dự đoán khác nhau, nhưng việc cùng xuất hiện chưa xác định feature là nguyên nhân. Muốn kiểm tra cơ chế cần một đối chứng có thể can thiệp và không làm thay đổi định nghĩa mẫu hoặc vô tình nhìn lại official TEST trong khâu thiết kế.

## 5.3 Vai trò và giới hạn của Feature Selection

Hai track 42 và 17 feature được so sánh dưới những cấu hình final khác nhau. RF-42 dùng 300 trees và `min_samples_leaf`=1; RF-17 dùng 150 trees và `min_samples_leaf`=2. Khi RF-17 có thời gian train thấp hơn, lợi ích quan sát được có thể do cả số cây, kích thước lá, số feature lẫn các tương tác giữa chúng. Một thí nghiệm ablation chuẩn để tách nguyên nhân phải giữ các tham số còn lại cố định, dùng cùng seed/protocol và lặp lại việc chọn feature bên trong vòng đánh giá.

Trong dự án, stable 17 features được chọn từ toàn TRAIN trước development CV. Official TEST không được dùng trực tiếp để ra danh sách, nhưng điểm CV sau bước chọn toàn TRAIN có thể vẫn lạc quan vì phép chọn đã thấy nhãn của một số fold trước khi chúng làm validation. Đây là giới hạn nghiêm túc, cần đặt ngay cạnh các kết luận về feature selection, không chỉ chép ở phần cuối. Dữ liệu đã lưu không đủ chứng minh rằng một quy trình nested được triển khai đầy đủ.

## 5.4 Sự khác biệt giữa kiểm định, bootstrap và độ ổn định

Paired bootstrap tạo phân bố hiệu số từ cùng các dòng TEST, giữ quan hệ ghép cặp của hai model. Đối với Macro-F1, CI 95% của Stacking-42 trừ RF-42 là [-0,000312; 0,001309]; với MCC là [-0,001938; 0,001140]. Hai khoảng chứa 0. Trong khi đó, CI FPR nằm hoàn toàn phía âm và CI FNR

nằm hoàn toàn phía dương. Bốn nhận xét phải được giữ cùng nhau: bằng chứng ủng hộ sự thay đổi loại lỗi trên benchmark, không khẳng định một chiến thắng về hiệu năng tổng quát.

Một phép bootstrap trên dòng không tái tạo sự ngẫu nhiên của quá trình tối ưu mô hình. Để đo ổn định do train, cần nhiều lần fit độc lập, có quản lý seed và khả năng so sánh đúng điều kiện compute. Để đo tổng quát hóa giữa các mạng, cần nhiều benchmark độc lập hoặc thiết kế theo thời gian/session. Không được gọi CI hiện tại là độ tin cậy triển khai ngoài dữ liệu hoặc dùng nó thay cho quá trình tái huấn luyện mô hình.

## 5.5 Giới hạn tái lập và kiểm tra artifact mới nhất

Phải phân biệt *mô hình lịch sử* tạo ra các điểm official TEST và *mô hình tái dựng* từ cấu hình đã khóa. Do lịch sử không lưu đầy đủ environment/package lock hay đối tượng model gốc, hiện chưa thể chứng minh hai loại artifact đồng nhất bitwise hoặc kiểm chứng lại scientific TEST metrics từ model gốc.

Tính đến 17/10/2026, nhóm đã tái dựng riêng RF-17, RF-42 và Stacking-42 trên **175 341 dòng official TRAIN**, với đúng frozen settings và threshold $0.5$. Cả ba run reports đều ghi PASS. Kiểm tra độc lập trên laptop của nhóm xác nhận cả ba serialized `joblib` tồn tại, khớp SHA-256/kích thước, có thể tải lại và chạy kiểm tra `predict_proba` trên 16 dòng *TRAIN-derived*, với tổng cộng 69/69 phép kiểm artifact đạt. Đây là *P15 DONE_SCOPED_RECONSTRUCTION*, không phải model lịch sử hay phép kiểm định scientific TEST lần thứ hai. Việc tái dựng diễn ra trong môi trường Python 3.11.9, scikit-learn 1.9.0; phiên bản thư viện gốc vẫn không xác định trực tiếp.

Mô hình smoke huấn luyện trên tập con TRAIN trước đó chỉ kiểm thử kỹ thuật và không thay thế ba artifact full TRAIN. Bằng chứng trên laptop tác giả khác với việc bên phản biện độc lập tiếp nhận, kiểm tra model bytes hoặc chấp thuận hệ thống IDS triển khai thật. Các điểm số official TEST/chi phí lịch sử trong Chương 4 được giữ nguyên, không bị thay bằng các số đo của lần P15 mới.

## 5.6 Tính hợp lệ bên ngoài và định hướng nghiên cứu tiếp

Official UNSW-NB15 TEST không phải một benchmark external độc lập với quá trình hình thành bộ dữ liệu. Novel-vector view là tập con của chính

official TEST, không đại diện phép kiểm tra temporal split, day split hay host-separated validation. Vì vậy việc tất cả model mất một phần Macro-F1 trên novel-vector view chỉ chứng minh độ nhạy theo định nghĩa chọn dòng đó, không mô tả lỗi trên traffic tương lai.

Một hướng tiếp tục đáng tin cậy là khóa trước các câu hỏi mới, định nghĩa đơn vị độc lập (session/host/time), huấn luyện trên một split có thể kiểm chứng, đánh giá external nếu có quyền truy cập và đối chiếu các số đo vận hành như FPR theo khối lượng traffic. Những thí nghiệm này phải được đặt thành nghiên cứu kế tiếp có train/test mới, không sửa frozen predictions hay threshold của nghiên cứu hiện tại. Việc công khai các giới hạn giữ cho báo cáo có giá trị học thuật ngay cả khi không có cải thiện rõ rệt của Stacking so với RF.

## 5.7 Tổng hợp kết luận theo câu hỏi nghiên cứu

Các phân tích và kết quả định lượng được trình bày riêng ở Mục 4.8 (Chương 4). Bảng 5.2 tóm tắt câu trả lời thay vì chỉ liệt kê những nguồn chưa có.

**Bảng 5.2.** Câu trả lời theo phạm vi đã có bằng chứng, không phải kết luận giả định.

| RQ | Kết quả trực tiếp từ thí nghiệm | Điều chưa xác nhận |
|---|---|---|
| RQ1 | Stacking không thể hiện ưu thế tổng thể rõ trên official TEST; bớt 142 FP nhưng thêm 118 FN. | Độ ổn định qua nhiều lần train. |
| RQ2 | RF-17 có chi phí lịch sử thấp hơn RF-42, Macro-F1 giảm 0.002670, FN giảm 26 nhưng FP tăng 221. | Tác động riêng của FS. |
| RQ3 | Base learners có double-fault/error correlation khác nhau; Voting kém RF, Stacking chỉ nhỉnh nhẹ ở development. | Cơ chế nhân quả do diversity. |
| RQ4 | Cả ba giảm Macro-F1 trên novel-vector view; thứ hạng giữ nguyên. | Tổng quát ngoài benchmark. |
| RQ5 | TRAIN nhiều Attack hơn Normal; giữa các pipeline có đánh đổi FPR/FNR. | Hiệu quả riêng của weight/resampling. |

Do hai câu hỏi RQ1 và RQ5 đòi hỏi điều kiện thực nghiệm chưa được thiết lập, câu trả lời khoa học là *chưa xác nhận ổn định/cơ chế* chứ không tự bổ sung bằng chứng. Các hạn chế về thiết kế không làm mất giá trị của các thống kê mô tả đã được khóa.

## 5.8 Kết luận và định hướng phát triển

### 5.8.1 Tổng kết kết quả

Trên official UNSW-NB15 TEST gồm 82 332 dòng, Stacking-42 đạt Macro-F1 khoảng 0.863840 so với 0.863343 của RF-42, trong khi MCC của Stacking-42 khoảng 0.750497, thấp hơn rất nhẹ so với 0.750910 của RF-42. Chênh lệch Macro-F1 Stacking-42 trừ RF-42 là khoảng $+0.000497$; khoảng tin cậy 95% paired bootstrap đã lưu gồm 0. Những bằng chứng này *không xác nhận ưu thế tổng thể* của Stacking-42 trên Macro-F1/MCC, và cũng không chứng minh hai mô hình tương đương về mặt thống kê.

Stacking-42 giảm 142 dự đoán báo động giả (FP) nhưng tăng 118 trường hợp bỏ sót tấn công (FN) so với RF-42. Phân tích hậu nghiệm cho thấy xu hướng lỗi khác nhau theo từng attack family: Stacking-42 có thêm 133 FN ở Fuzzers nhưng giảm 43 FN ở Generic. Những con số đó thuộc mô hình *binary* và nhãn thật của các nhóm, không phải khả năng dự đoán multiclass hay bằng chứng về nguyên nhân từ các feature riêng lẻ.

RF-17 có Macro-F1 thấp hơn RF-42 một lượng nhỏ, đổi lại các số đo lịch sử cho thấy thời gian train ngắn hơn và ước lượng dung lượng mô hình giảm. Tuy nhiên, đây là so sánh *pipeline-level* vì RF-17 không chỉ giảm đặc trưng mà còn thay đổi siêu tham số Random Forest. Không thể quy trực tiếp mọi thay đổi cho riêng Feature Selection.

### 5.8.2 Giải đáp các câu hỏi nghiên cứu

**RQ1:** Dữ liệu official không cho thấy Stacking-42 vượt RF-42 rõ rệt về paired Macro-F1/MCC; việc bớt FP nhưng tăng FN là đánh đổi, còn ổn định repeated training chưa đo. **RQ2:** RF-17 giảm chi phí lịch sử và thay đổi hiệu năng so với RF-42, nhưng vì cùng thay hyperparameters nên không kết luận hiệu ứng riêng của Feature Selection. **RQ3:** Dữ liệu OOF cho thấy sai số bổ sung giữa base learners; việc Voting không tốt hơn RF cho thấy diversity không tự dẫn đến gain, và chưa chứng minh cơ chế nhân quả. **RQ4:** Macro-F1 giảm ở novel-vector subset của cả ba pipeline nhưng thứ hạng giữ nguyên; kết quả không đại diện external validation. **RQ5:** Mất cân bằng support và đánh đổi FPR/FNR có thể quan sát; do không có matched resampling/weighting study nên chưa xác định lợi ích riêng của cách xử lý mất cân bằng. Các số liệu, bảng và mức giảm cụ thể nằm trong Mục 4.8; việc chưa thể xác nhận một giả thuyết *không* được chuyển thành khẳng định thành công.

### 5.8.3 Đóng góp trong phạm vi đã chứng minh

Đóng góp có thể bảo vệ ở thời điểm hiện tại là một chuỗi thực nghiệm trên benchmark có nguồn và cấu hình đóng băng, có kiểm toán dữ liệu, đối chiếu mô hình học máy đơn và ensemble, phân tích sai số bổ sung, khoảng tin cậy cho chênh lệch theo cặp, đánh đổi FP/FN và chi phí. Kết quả không thuận lợi của Voting và sự thiếu ưu thế rõ ràng của Stacking là thành phần của kết luận khoa học, không bị loại vì không hỗ trợ một giả thuyết chiến thắng.

Báo cáo cũng ghi nhận các giới hạn của phép đo: sai lệch tiềm tàng do Feature Selection trước development CV, meta tuning chưa fully nested, vector TRAIN/TEST bị trùng, benchmark flow có thể phụ thuộc lẫn nhau, thiếu temporal/external validation và thiếu bằng chứng ổn định qua các lần tái huấn luyện độc lập. Việc công khai những giới hạn này góp phần tránh suy diễn vượt mức về khả năng tổng quát hoặc tính mới của thuật toán.

### 5.8.4 Công việc còn thiếu và hướng nghiên cứu

Với RQ1, cần một nghiên cứu mới có nhiều lần huấn luyện độc lập, cùng tài nguyên và môi trường đã khóa để kiểm tra tính ổn định của hiệu số. Với RQ2, cần thí nghiệm matched và nested feature selection, giữ các tham số còn lại cố định để tách tác động của chính Feature Selection. Với RQ3, có thể kiểm tra giả thuyết về cơ chế bổ sung sai số bằng phân tích độc lập thay vì chỉ dùng profile hậu nghiệm. Với RQ4, cần nguồn có thông tin thời gian/session hoặc một external benchmark đáng tin cậy để đánh giá ngoài official split. Với RQ5, có thể thiết kế đối chứng resampling/class-weight bên trong training folds, nhưng không được dựa vào official TEST hiện tại để chọn phương án thắng.

Mã nguồn xử lý, huấn luyện và tổng hợp chỉ số tạo điều kiện kiểm tra quy trình thực nghiệm và tính nhất quán của các kết quả. Môi trường huấn luyện lịch sử vẫn chưa đủ thông tin để xác nhận *bitwise identity*. Tại checkpoint ngày 17/10/2026, ba frozen pipeline đã được tái dựng trên toàn 175 341 dòng official TRAIN và lưu thành ba artifact `RECONSTRUCTED_FULL_TRAIN`; các phép xác minh trên laptop tác giả đạt 69/69 (SHA-256, schema, tải model và suy luận trên 16 dòng TRAIN). Đây là kết quả tái dựng có phạm vi, *không* xác nhận model gốc, không tái đánh giá scientific TEST và không chứng minh hệ thống NIDS sẵn sàng triển khai. Các smoke model trên TRAIN nhỏ vẫn chỉ giữ vai trò thử kỹ thuật.

### 5.8.5 Kết luận cuối

Trong phạm vi benchmark và thí nghiệm đã khóa, kết quả chủ yếu nhấn mạnh nhu cầu so sánh Ensemble Learning một cách có kiểm soát, trình bày đầy đủ loại lỗi và độ bất định, thay vì chọn mô hình chỉ bởi một điểm Accuracy hoặc Macro-F1 nhỉnh hơn về mặt số học. Việc bổ sung Stacking đem lại một đánh đổi FP/FN cụ thể nhưng không xác lập ưu thế tổng thể trước RF-42. Các đóng góp có thể truy vết nằm ở cách đánh giá và diễn giải kết quả, không phải một cam kết superiority, novelty hoặc deployment chưa được kiểm chứng.

# Tài liệu tham khảo

[1] Ali Mohammed Alsaffar, Mostafa Nouri-Baygi, and Hamed M. Zolbanin. Shielding networks: enhancing intrusion detection with hybrid feature selection and stack ensemble learning. *Journal of Big Data*, 11(1):133, 2024.

[2] Marco Cantone, Claudio Marrocco, and Alessandro Bria. Machine learning in network intrusion detection: A cross-dataset generalization study. *IEEE Access*, 12:144489–144508, 2024.

[3] Doreswamy, Mohammad Kazim Hooshmand, and Ibrahim Gad. Feature selection approach using ensemble learning for network anomaly detection. *CAAI Transactions on Intelligence Technology*, 5(4):283–293, 2020.

[4] Gints Engelen, Vera Rimmer, and Wouter Joosen. Troubleshooting an intrusion detection dataset: the cicids2017 case study. In *2021 IEEE Security and Privacy Workshops (SPW)*, pages 7–12, 2021.

[5] Murad Ali Khan, Naeem Iqbal, Imran, Harun Jamil, and Do-Hyeun Kim. An optimized ensemble prediction model using automl based on soft voting classifier for network intrusion detection. *Journal of Network and Computer Applications*, 212:103560, 2023.

[6] Nour Moustafa and Jill Slay. Unsw-nb15: a comprehensive data set for network intrusion detection systems (unsw-nb15 network data set). In *2015 Military Communications and Information Systems Conference (MilCIS)*, pages 1–6, 2015.

[7] Ghalia Nassreddine, Mohamad Nassereddine, and Obada Al-Khatib. Ensemble learning for network intrusion detection based on correlation and embedded feature selection techniques. *Computers*, 14(3):82, 2025.

[8] Huajuan Ren, Yonghe Tang, Weiyu Dong, Shuai Ren, and Liehui Jiang. Duen: Dynamic ensemble handling class imbalance in network intrusion detection. *Expert Systems with Applications*, 229:120420, 2023.

[9] Ulya Sabeel, Shahram Shah Heydari, Khalil El-Khatib, and Khalid Elgazzar. Unknown, atypical and polymorphic network intrusion

detection: A systematic survey. *IEEE Transactions on Network and Service Management*, 21(1):1190–1212, 2024.

[10] Bayu Adhi Tama and Sunghoon Lim. Ensemble learning for intrusion detection systems: A systematic mapping study and cross-benchmark evaluation. *Computer Science Review*, 39:100357, 2021.

[11] Ngamba Thockchom, Moirangthem Marjit Singh, and Utpal Nandi. A novel ensemble learning-based model for network intrusion detection. *Complex & Intelligent Systems*, 9(5):5693–5714, 2023.

[12] Mubarak Albarka Umar, Zhanfang Chen, Khaled Shuaib, and Yan Liu. Effects of feature selection and normalization on network intrusion detection. *Data Science and Management*, 8(1):23–39, 2025.

[13] Houssam Zouhri, Ali Idri, and Ahmed Ratnani. Evaluating the impact of filter-based feature selection in intrusion detection systems. *International Journal of Information Security*, 23(2):759–785, 2024.